

Inferência Estatística com Abordagem Bayesiana

Rosangela Helena Loschi ¹

¹Departamento de Estatística
Universidade Federal de Minas Gerais

16 de dezembro de 2021

INFERÊNCIA E DECISÃO

- ▶ Problema de Decisão
- ▶ Inferência Pontual
- ▶ Regiões de credibilidadee
- ▶ Testes de Hipóteses

Metodologia Inferencial

Em Estatística Bayesiana

- * A melhor e mais completa inferência sobre o parâmetro de interesse é a distribuição *a posteriori*.
- * A distribuição *a posteriori* é **TUDO** o que se necessita saber para se obter
 - + Estimativas pontuais
 - + Intervalos ou regiões de credibilidade
 - + Testar hipóteses.
- * As estimativas (pontuais ou por regiões) e a evidência sobre as hipóteses são resumos da distribuição *a posteriori*.
- * Por tanto, a única amostra que se considera para se fazer inferência e tomar decisões é **a amostra observada**.

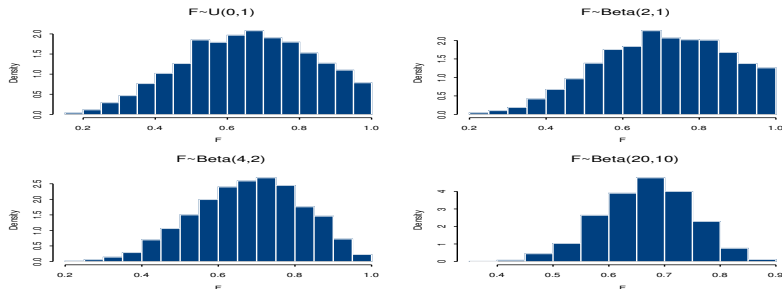
Metodologia Inferencial

- ▶ Na prática queremos resumir a informação atualizada para facilitar nossa comunicação.
- ▶ Esta análise *a posteriori* passa por
 - ▶ uma análise gráfica da distribuição *a posteriori*.
 - ▶ obter resumos de localização da distribuição *a posteriori* (como a média, a moda e a mediana que seriam nossas estimativas pontuais); resumos de dispersão (como a variância *a posteriori* e quantis o que nos dá uma idéia do grau de conhecimento adquirido sobre o parâmetro) etc.
- ▶ a análise gráfica é muito útil pois nos permite ver
 - ▶ as regiões do espaço paramétrico Θ com mais massa probabilística, revelando os valores mais prováveis de θ .
 - ▶ multimodalidade: os valores mais prováveis de θ pertencem a intervalos / regiões não conectadas
 - ▶ assimetria, revelando que valores de θ de um lado da distribuição *a posteriori* são mais prováveis do que os valores θ do outro lado da curva.

Análise dos Dados de Síndrome de Down: Distribuições *a posteriori*

$F = \phi$ probabilidade de que a não disjunção ocorra na primeira fase da meiose.

Figure: Distribuições *a posteriori* (método SIR)



Análise dos Dados de Síndrome de Down: Distribuições *a posteriori*

- ▶ Qual resumo melhor resumiria a distribuição *a posteriori*?
 - ▶ A moda parece sempre resumir bem a informação. Seria este o caso se a distribuição fosse bimodal??
 - ▶ No caso de distribuições assimétricas a média pode não ser um bom resumo pois pode estar longe da região com mais massa probabilística.
- ▶ Se o pesquisador afirma que $\phi < 0,5$ que decisão você tomaria sobre esta afirmação?
 - ▶ Se *a priori* $\phi \sim \text{Beta}(20, 10)$, então $P(\phi < 0,5 \mid \mathbf{x}) \approx 0$.
Evidência contra a afirmação do pesquisador.

Table: Análise dos Dados de Síndrome de Down Estimadores de Bayes

<i>Especificação a Priori</i>					<i>Resultados a Posteriori -SIR</i>		
α	β	Média	Var	Moda	Média	Var	Moda
1.0	1.0	0.500	0.080	—	0.6571	0.0311	0.6690
2.0	1.0	0.667	0.060	1.000	0.7043	0.0268	0.6842
4.0	2.0	0.667	0.030	0.750	0.6498	0.0194	0.7147
20.0	10.0	0.667	0.007	0.677	0.6671	0.0065	0.6765

- ▶ Quando *a priori* assumimos que $\phi \sim \text{Beta}(20, 10)$ obtivemos uma distribuição *a posteriori* mais simétrica.
- ▶ Consequência: as estimativas pontuais usando a média e a moda ficaram bem próximas.
- ▶ O que a variância nos diz? O qual certos estamos sobre o valor real de ϕ *a posteriori*.

Como escolher o estimador de Bayes?

Estimação Pontual

- ▶ A escolha dos estimadores Bayesianos de $\theta \in \Theta \subseteq \mathbb{R}^k$ depende da forma da distribuição *a posteriori*.
- ▶ Ou da forma como escolhemos para sermos penalizados por nossas ações equivocadas (ver adiante).
- ▶ Os estimadores pontuais mais utilizados são **média**, **moda** e **mediana** *a posteriori*.
- ▶ Estes estimadores fornecem estimativas não muito similares se a distribuição *a posteriori* é assimétrica ou multimodal.
- ▶ Os resumos *a posteriori* no caso multiparamétrico são generalizações dos resumos no caso uniparamétrico.

Estimação Pontual

Seja $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)$ e denote por $\pi(\boldsymbol{\theta} \mid \mathbf{x})$ a distribuição *a posteriori* de $\boldsymbol{\theta}$.

- **Moda a posteriori:** é um vetor $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ tal que

$$\pi(\hat{\boldsymbol{\theta}} \mid \mathbf{x}) = \max_{\boldsymbol{\theta} \in \Theta} \pi(\boldsymbol{\theta} \mid \mathbf{x}) = \max_{\boldsymbol{\theta} \in \Theta} \pi(\boldsymbol{\theta}) f(\mathbf{x} \mid \boldsymbol{\theta})$$

- **Média a posteriori:** é um vetor $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ tal que

$$\hat{\boldsymbol{\theta}} = E(\boldsymbol{\theta} \mid \mathbf{x}) = (E(\theta_1 \mid \mathbf{x}), \dots, E(\theta_k \mid \mathbf{x}))$$

onde $E(\theta_i \mid \mathbf{x}) = \hat{\theta}_i = \int_{\Theta} \theta_i \pi(\theta_i \mid \mathbf{x}) d\theta_i$, $i = 1, \dots, k$.

- **Mediana a posteriori:** é um vetor $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ tal que

$$P(\theta_i \geq \hat{\theta}_i \mid \mathbf{x}) = 1/2 \text{ e } P(\theta_i \leq \hat{\theta}_i \mid \mathbf{x}) = 1/2, \quad i = 1, \dots, k.$$

Estimação Pontual: Características importantes

- a) Apenas a moda *a posteriori* pode ser obtida conhecendo-se apenas o núcleo da distribuição *a posteriori*.
- b) para obtermos a média e a mediana *a posteriori* temos que conhecer a distribuição *a posteriori* completamente. No caso multiparamétrico temos que conhecer as distribuições marginais *a posteriori* completamente.
- c) Se a distribuição *a priori* é uma constante K então a moda *a posteriori* é igual ao estimador de máxima verossimilhança (EMV) do parâmetro.

$$\max_{\theta \in \Theta} \pi(\theta | \mathbf{x}) = \max_{\theta \in \Theta} \pi(\theta) f(\mathbf{x} | \theta) = \max_{\theta \in \Theta} K f(\mathbf{x} | \theta) = \max_{\theta \in \Theta} f(\mathbf{x} | \theta)$$

- d) o valor θ onde a distribuição *a posteriori* assume valor máximo **não** é, necessariamente, o vetor formado pelas modas *a posteriori* das distribuições *a posteriori* marginais de cada componente de θ_i .

Estimação Pontual: Características importantes

Exemplo (Ilustrando (c) e (d)): Se X_1, \dots, X_n , dado μ e σ^2 , são variáveis aleatórias i.i.d com distribuição Normal(μ, σ^2), em que μ e σ^2 são desconhecidas. Se, *a priori*, a distribuição para (μ, σ^2) é $\mu \mid \sigma^2 \sim \text{Normal}(m, V\sigma^2)$ e $\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d)$. Então, A distribuição *a posteriori* é

$$\begin{aligned}\mu \mid \sigma^2, \mathbf{x} &\sim N\left(\frac{nV\bar{x} + m}{nV + 1}, \frac{V}{nV + 1}\sigma^2\right) = N(m^*, V^*\sigma^2) \\ \sigma^2 \mid \mathbf{x} &\sim \text{Gama} - \text{Inversa}\left(a + \sum_{i=1}^n x_i^2 + \frac{m^2}{V} - \frac{(nV\bar{x} + m)^2}{V(nV + 1)}, d + n\right) \\ &= \text{Gama} - \text{Inversa}(a^*, d^*)\end{aligned}$$

Encontre os estimadores de Bayes para (μ, σ^2) .

Solução:

► As distribuições *a posteriori* marginais de μ e σ^2 , são:

$$\begin{aligned}\mu \mid \mathbf{x} &\sim t(m^*, V^*, a^*, d^*) \\ \sigma^2 \mid \mathbf{x} &\sim \text{Gama} - \text{Inversa}(a^*, d^*)\end{aligned}$$

Estimação Pontual: Características importantes

- Média *a posteriori*:

$$(\hat{\mu}, \hat{\sigma}^2) = (E(\mu | \mathbf{x}), E(\sigma^2 | \mathbf{x})) = \left(m^*, \frac{a^*}{d^* - 2}\right)$$

- Mediana *a posteriori*:

$$(\hat{\mu}, \hat{\sigma}^2) = (Md(\mu | \mathbf{x}), Md(\sigma^2 | \mathbf{x})) = (m^*, F_{GI}^{-1}(1/2, a^*, d^*))$$

onde $F_{GI}^{-1}(1/2, a^*, d^*)$ é a inversa da FDA da distribuição Gama-Inversa com parâmetros a^* e d^* avaliada no ponto 1/2.

- Como fazemos. Seja M a mediana que procuramos. Então

$$\int_0^M \pi(\sigma^2 | \mathbf{x}) d\sigma^2 = 1/2 \Rightarrow F_{GI}(M, a^*, d^*) = 1/2$$

$$\Rightarrow M = F_{GI}^{-1}(1/2, a^*, d^*).$$

Estimação Pontual: Características importantes

Solução:

- ▶ Moda *a posteriori*: Temos que encontrar $(\hat{\mu}, \hat{\sigma}^2)$ que maximizam a distribuição a posteriori.
- ▶ maximizaremos $\ln \pi(\mu, \sigma^2 | \mathbf{x})$

$$\ln \pi(\mu, \sigma^2 | \mathbf{x}) = \ln K - \frac{d^* + 3}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \left[a^* + \frac{(\mu - m^*)^2}{V^*} \right]$$

$$\frac{\partial}{\partial \mu} \ln \pi(\mu, \sigma^2 | \mathbf{x}) = \frac{(\mu - m^*)}{V^* \sigma^2} = 0 \Rightarrow \hat{\mu} = m^*$$

$$\frac{\partial}{\partial \sigma^2} \ln \pi(\mu, \sigma^2 | \mathbf{x}) = -\frac{d^* + 3}{2\sigma^2} + \frac{(\mu - m^*)^2 / V^* + a^*}{(\sigma^2)^2} = 0$$

$$\Rightarrow \hat{\sigma}^2 = \frac{a^*}{d^* + 3}$$

- ▶ O ponto $(\hat{\mu}, \hat{\sigma}^2) = (m^*, a^*/(d^* + 3))$ é candidato a ponto de máximo.

Estimação Pontual: Características importantes

- ▶ a matriz Hessiana com as segundas derivadas parciais é:

$$H(\mu, \sigma^2) = \begin{bmatrix} -\frac{1}{V^* \sigma^2} & \frac{(\mu - m^*) V^*}{(\sigma^2)^2} \\ \frac{(\mu - m^*) V^*}{(\sigma^2)^2} & -\frac{2a^*}{(\sigma^2)^3} + \frac{(d^* + 3)}{(\sigma^2)^2} \end{bmatrix}$$

- ▶ o determinante de $H(\mu, \sigma^2)$ avaliado em $(\hat{\mu}; \hat{\sigma}^2) = (m^*; a^*/(d^* + 3))$ é

$$\frac{1}{(a^*)^2} \frac{(d^* + 3)^4}{a^* V^*} > 0$$

- ▶ Como $\det H(\mu, \sigma^2) > 0$ e $\frac{\partial^2}{\partial \mu^2} < 0$ concluímos que a moda *a posteriori* é

$$(\hat{\mu}; \hat{\sigma}^2) = (m^*; a^*/(d^* + 3)).$$

Estimação Pontual: Características importantes

Observação importante relacionado ao Exemplo:

- Note que, neste caso, as distribuições marginais de μ e σ^2 , são:

$$\mu \mid \mathbf{x} \sim t(m^*, V^*, a^*, d^*)$$

$$\sigma^2 \mid \mathbf{x} \sim \text{Gama} - \text{Inversa}(a^*, d^*)$$

- a moda das distribuições marginais são

$$\text{Moda}(\mu \mid \mathbf{x}) = m^*$$

$$\text{Moda}(\sigma^2 \mid \mathbf{x}) = \frac{a^*}{d^* + 2}$$

- Note que é diferente da moda encontrada anteriormente. Logo, a moda da distribuição conjunta não é formada pela moda das distribuições marginais.

Estimação Pontual: Características importantes

- e) Os Estimadores de Bayes não possuem a propriedade da invariância observada para os estimadores de máxima verossimilhança.
- ▶ Se $\hat{\theta}$ é o EMV para θ então o EMV para $g(\theta)$ é $g(\hat{\theta})$.
 - ▶ No caso Bayesiano, para encontrarmos a estimativa de $g(\theta)$, precisamos encontrar a distribuição *a posteriori* de $g(\theta)$.

Exemplo: Sejam X_1, \dots, X_n v.a. que, dado θ , são i.i.d com distribuição *Bernoulli*(θ). Assuma a distribuição *a priori* de Bayes-Laplace para θ . (a) Estime θ^2 usando o método da Máxima Verossimilhança.

Solução: (a) Os EMV gozam da propriedade de invariância, isto é podemos utilizar o método *plug-in* para encontrarmos o EMV de θ^2 . Pelo método da máxima verossimilhança, o estimador para θ é $\hat{\theta}_{MV} = \bar{X} \Rightarrow$ o EMV para θ^2 é $\hat{\theta}_{MV}^2 = \bar{X}^2$.

Estimação Pontual: Características importantes

(b) Estime θ^2 utilizando a média *a posteriori*.

Solução: (b) Como a distribuição de Bayes-Laplace para θ é a $Uniforme(0, 1) = Beta(1, 1)$, por causa da conjugação temos que a distribuição *a posteriori* para θ é

$$\theta \mid \mathbf{x} \sim Beta\left(1 + \sum_{i=1}^n x_i; 1 + n - \sum_{i=1}^n x_i\right) = Beta(\alpha^*, \beta^*)$$

Podemos considerar duas estratégias

- ▶ Encontramos a distribuição *a posteriori* de θ^2 e, a partir dela, sua média.
- ▶ Utilizamos alguma propriedade que nos permita encontrar $E(\theta^2 \mid \mathbf{x})$.

Estimação Pontual: Características importantes

Usando propriedades de esperança temos

$$\begin{aligned}\hat{\theta}^2 &= E(\theta^2 | \mathbf{x}) = V(\theta | \mathbf{x}) + [E(\theta | \mathbf{x})]^2 \\ &= \frac{\alpha^* \beta^*}{(\alpha^* + \beta^*)^2 (\alpha^* + \beta^* + 1)} + \left(\frac{\alpha^*}{(\alpha^* + \beta^*)} \right)^2 \\ &= \left(\frac{\alpha^*}{\alpha^* + \beta^*} \right)^2 \left[\frac{\beta^*}{\alpha^* (\alpha^* + \beta^* + 1)} + 1 \right]\end{aligned}\quad (1)$$

- ▶ Se a propriedade da invariância fosse válida deveria valer o método *Plug-in*. Como a média *a posteriori* para θ é

$$\hat{\theta} = E(\theta | \mathbf{x}) = \frac{\alpha^*}{\alpha^* + \beta^*},$$

usando o método *plug-in*, a média *a posteriori* ou estimativa *a posteriori* de θ^2 deveria ser

$$\hat{\theta}^2 = (E(\theta | \mathbf{x}))^2 = \left(\frac{\alpha^*}{\alpha^* + \beta^*} \right)^2$$

- ▶ Esta estimativa difere da estimativa em (1). Ela é errada pois estamos utilizando o método *plug-in* que não é aplicável no contexto Bayesiano.

Estimação Pontual: Características importantes

(b) Estime θ^2 utilizando a moda *a posteriori*.

- ▶ Neste caso precisamos encontrar a distribuição *a posteriori* de $\phi = \theta^2$.
- ▶ usando resultados de probabilidade, para todo $\phi > 0$, temos

$$\pi(\phi | \mathbf{x}) = \frac{1}{2\sqrt{\phi}} [\pi_{\theta}(\sqrt{\phi} | \mathbf{x}) + \pi_{\theta}(-\sqrt{\phi} | \mathbf{x})]$$

- ▶ como $\theta \sim \text{Beta}(\alpha^*, \beta^*)$, então $\pi_{\theta}(-\sqrt{\phi} | \mathbf{x}) = 0$.
- ▶ A distribuição *a posteriori* para ϕ é

$$\pi(\phi | \mathbf{x}) = \frac{1}{2\sqrt{\phi}} \frac{\Gamma(\alpha^* + \beta^*)}{\Gamma(\alpha^*)\Gamma(\beta^*)} (\sqrt{\phi})^{\alpha^*-1} (1-\sqrt{\phi})^{\beta^*-1}, \quad 0 < \phi < 1.$$

$$\pi(\phi | \mathbf{x}) = \frac{\Gamma(\alpha^* + \beta^*)}{2\Gamma(\alpha^*)\Gamma(\beta^*)} (\sqrt{\phi})^{\alpha^*-2} (1 - \sqrt{\phi})^{\beta^*-1}, \quad 0 < \phi < 1. \quad (2)$$

Estimação Pontual: Características importantes

Para achar a moda *a posteriori* de $\phi = \theta^2$ encontramos o máximo da distribuição dada na equação (2).

$$\frac{d}{d\phi} \ln \pi(\phi | \mathbf{x}) = \frac{\alpha^* - 2}{2\phi} - \frac{(\beta^* - 1)\phi^{-1/2}}{2(1 - \sqrt{\phi})}$$

Igualando a zero temos

$$\frac{\alpha^* - 2}{2\phi} = \frac{(\beta^* - 1)\phi^{-1/2}}{2(1 - \sqrt{\phi})} \Rightarrow (\alpha^* - 2)(1 - \phi^{1/2}) = (\beta^* - 1)\phi^{1/2}$$

O candidato a máximo é

$$\hat{\phi} = \left(\frac{\alpha^* - 2}{\alpha^* + \beta^* - 3} \right)^2$$

e existe se $\alpha^* + \beta^* \neq 3$. (Deixo como exercício o cálculo e estudo da segunda para avaliar sob que condições $\hat{\phi}$ é ponto de máximo.)

Problema de decisão

Em Estatística Bayesiana, os problemas de estimação e teste de hipóteses são tratados como um **problema de decisão**.

- ▶ Elementos de um problema de decisão no contexto de inferência são:
 - (1) Espaço de ações \mathcal{A} : conjunto de possíveis ações ou decisões ou respostas para o problema de inferência;
 - + Exemplo: a) Aceitar ou rejeitar uma hipótese. b) fornecer uma estimativa para o parâmetro
 - (2) Espaço Θ de todos os estados da natureza ou espaço paramétrico.
 - + Exemplo: conjunto dos valores do parâmetro de interesse.
 - (3) Espaço amostral \mathcal{X} : conjunto de todos os possíveis resultados de um experimento.
 - (4) Regra de Decisão $a(x)$ é uma função definida de \mathcal{X} em \mathcal{A} .
 - + Exemplo: (a) Critério para a tomada de decisão sobre as hipóteses. (b) escolha de um estimador
 - (5) Função perda $L(a, \theta) : \Theta \times \mathcal{A} \rightarrow \mathbb{R}^+$

Problema de decisão

A função perda $L(a, \theta)$ é uma **escolha subjetiva** que representa a perda que se sofre por escolher a ação $a(x) = a$ quando θ é o verdadeiro estado da natureza.

* Alguns exemplos

(1) perda quadrática: $L(a, \theta) = (a - \theta)^2$

(2) perda absoluta: $L(a, \theta) = |a - \theta|$

(3) perda zero-um: $L(a, \theta) = \lim_{\epsilon \rightarrow 0} 1(|a - \theta| > \epsilon)$.

► OBS: Se Θ é enumerável então a perda zero-um pode ser escrita da seguinte forma:

$$L(a, \theta) = 1 \text{ se } a \neq \theta$$

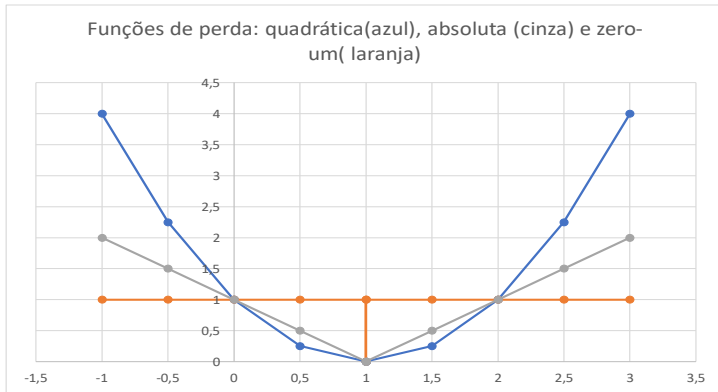
$$L(a, \theta) = 0 \text{ se } a = \theta$$

- .
- No contexto Bayesiano, θ é aleatório pois é desconhecido.
- $L(a, \theta)$ é aleatória pois depende de θ .

Problema de decisão

Exemplo:

Suponha que se escolha a ação $a(x) = a = \bar{x}$. Se observamos que $\bar{x} = 1$ temos que, para todo $\theta \in \mathbb{R}$, a perda quadrática é $L(a, \theta) = (1 - \theta)^2$, a perda absoluta é $L(a, \theta) = |1 - \theta|$ e a perda zero-um é $L(a, \theta) = 0$ se $\theta = \bar{x} = 1$ e $L(a, \theta) = 1$ se $\theta = \bar{x} \neq 1$.



Problema de decisão

- ▶ A perda zero-um penaliza da mesma forma se você errou o valor de θ por pouco ou por muito.
- ▶ Se o valor real de θ dista pouco de 1 (está entre 0 e 2) a perda quadrática impõe a menor penalização de nossa decisão.
- ▶ Se o valor real de θ dista muito de 1 (é menor que 0 ou maior que 2) a perda quadrática impõe a maior penalização de nossa decisão.

Problema de decisão

- * As decisões são feitas considerando o **risco a posteriori** das ações.
- * Risco de uma ação ou decisão $a \in \mathcal{A}$ é a perda esperada *a posteriori* dada por

$$R(a, x) = \int_{\Theta} L(a, \theta) \pi(\theta|x) d\theta.$$

- * A **ação ótima** ou **regra de Bayes** é a ação a^* tal que

$$a^* = \min_a R(a, x).$$

- * **Risco de Bayes** \leftarrow é o risco associado à decisão ótima $R(a^*, x)$.

Problema de decisão

Exemplo (Migon & Gamerman (1993)): Se você é um médico e tem que decidir se envia ($a = 1$) ou não ($a = 0$) um paciente à uma cirurgia. Se a probabilidade do paciente estar doente ($\theta = 1$) é π (desconhecido) e se sua função de perda é

$$L(a, \theta) = \begin{cases} 0 & \text{se } \theta = 0, a = 0 \\ 500 & \text{se } \theta = 0, a = 1 \\ 1000 & \text{se } \theta = 1, a = 0 \\ 100 & \text{se } \theta = 1, a = 1 \end{cases} \quad (3)$$


Problema de decisão

Neste problema, os riscos associados a cada ação são:

$$R(0, x) = 0(1 - \pi) + 1000\pi = 1000\pi$$

$$R(1, x) = 500(1 - \pi) + 100\pi = 500 - 400\pi.$$

Qual ação é melhor? Que decisão tomar? ← depende da prevalência π da doença na população



Problema de decisão

- ▶ A decisão depende da incerteza que o médico tem sobre a prevalência da doença na população π .
- ▶ A decisão ótima é
 - (1) Se $\pi > 0.357$, a regra de Bayes é $a = 1$ (indicar cirurgia)
 - (2) Se $\pi < 0.357$, a regra de Bayes é $a = 0$ (não indicar cirurgia)
 - (3) Se $\pi = 0.357$ não existe uma regra de Bayes.

Estimação Pontual como um problema de Decisão

- ▶ Em Estatística Bayesiana os problemas de Inferência podem ser vistos como problemas de decisão.

DEFINIÇÃO: Um **estimador de Bayes** é uma regra de Bayes segundo a função de perda que você escolhe, ou seja, se a função de perda é $L(a, \theta)$ então o estimador de Bayes é

$$\hat{\theta}_B = \min_a E(L(a, \theta)|x)$$

Estimação Pontual como um problema de Decisão

Alguns Fatos Importantes:

- (1) Se assumimos a função de perda quadrática, então o estimador de Bayes é a média *a posteriori*.

Prova:

$$\begin{aligned}E[L(a, \theta) \mid x] &= E((\theta - a)^2 \mid x) \\&= E [(\theta - E(\theta \mid x)) - (a - E(\theta \mid x))]^2 \mid x] \\&= E [(\theta - E(\theta \mid x))^2 \mid x] - 2E [(\theta - E(\theta \mid x))(a - E(\theta \mid x)) \mid x] \\&\quad + E [(a - E(\theta \mid x))^2 \mid x] \\&= \text{Var}(\theta \mid x) - 2(a - E(\theta \mid x))E [(\theta - E(\theta \mid x)) \mid x] \\&\quad + E [(a - E(\theta \mid x))^2 \mid x] \\&= \text{Var}(\theta \mid x) + (a - E(\theta \mid x))^2\end{aligned}$$

Como $(a - E(\theta \mid x))^2 \geq 0$ para qualquer que seja a ação a , então $E[L(a, \theta) \mid x]$ é mínima quando

$$a = E(\theta \mid x)$$

Estimação Pontual como um problema de Decisão

(2) Se assumimos a função de perda zero-um, o estimador de Bayes é a moda *a posteriori*.

Prova: Assuma Θ enumerável. Daí, a regra de Bayes é:

$$\begin{aligned}\hat{\theta} &= \min_{a \in \Theta} E(L(a, \theta) \mid \mathbf{x}) \\ &= \min_{a \in \Theta} \{0 \times P(a = \theta \mid \mathbf{x}) + 1 \times P(a \neq \theta \mid \mathbf{x})\} \\ &= \min_{a \in \Theta} \{P(a \neq \theta \mid \mathbf{x})\} \\ &= \min_{a \in \Theta} \left\{ \sum_{\forall \theta \neq a} P(\theta \mid \mathbf{x}) \right\}\end{aligned}\tag{4}$$

Como a soma na expressão (4) envolve apenas valores maiores ou iguais a zero, $\sum_{\forall \theta \neq a} P(\theta \mid \mathbf{x})$ será mínima se excluirmos o maior valor de $P(\theta \mid \mathbf{x}) \Rightarrow$ a tem que ser o valor de θ tal que $P(\theta \mid \mathbf{x})$.
 \Rightarrow a ação ótima a tem que ser a moda *a posteriori*.

Estimação Pontual como um problema de Decisão

Coloquemos em números: Considere $\Theta = \{1, 2, 3\}$ e que $P(\theta = 1 \mid \mathbf{x}) = 2/3$ e $P(\theta = 2 \mid \mathbf{x}) = P(\theta = 3 \mid \mathbf{x}) = 1/6$.

► Se $a = 1$ então

$$\sum_{\theta \neq 1} P(\theta \mid \mathbf{x}) = P(\theta = 2 \mid \mathbf{x}) + P(\theta = 3 \mid \mathbf{x}) = 2/6$$

► Se $a = 2$ então

$$\sum_{\theta \neq 2} P(\theta \mid \mathbf{x}) = P(\theta = 1 \mid \mathbf{x}) + P(\theta = 3 \mid \mathbf{x}) = 5/6$$

► Se $a = 3$ então

$$\sum_{\theta \neq 3} P(\theta \mid \mathbf{x}) = P(\theta = 1 \mid \mathbf{x}) + P(\theta = 2 \mid \mathbf{x}) = 5/6$$

Se escolhemos $a = 1$ minimizamos a soma $\sum_{\theta \neq a} P(\theta \mid \mathbf{x})$. Isto implica que $a = 1$ é a decisão ótima e $\theta = 1$ é a moda.

Estimação Pontual como um problema de Decisão

Prova para Θ geral: Seja $P_{\theta|x}$ a medida *a posteriori* para θ .

$$\begin{aligned} R(a^*, x) &= \min_{a \in \Theta} \{ \lim_{\epsilon \rightarrow 0} [1 - P(a - \epsilon < \theta < a + \epsilon \mid x)] \} \\ &= \min_{a \in \Theta} \{ 1 - \lim_{\epsilon \rightarrow 0} P(a - \epsilon < \theta < a + \epsilon \mid x) \}. \\ &= 1 - \min_{a \in \Theta} \{ \lim_{\epsilon \rightarrow 0} P(a - \epsilon < \theta < a + \epsilon \mid x) \}. \end{aligned}$$

Como $\epsilon \rightarrow 0$, a sequência $P(a - \epsilon < \theta < a + \epsilon \mid x)$ define uma sequência que decresce para $\int_a^a dP_{\theta|x}(a) = P_{\theta|x}(a)$. Assim, temos que

$$R(a^*, x) = 1 - \min_{a \in \Theta} [P_{\theta|x}(a)] \rightarrow a = Mo(\theta \mid x).$$

Estimação Pontual como um problema de Decisão

(3) Se assumimos a função de perda absoluta, então o estimador de Bayes é a mediana *a posteriori*.

Prova: Assuma que $\theta \in \mathbb{R}$. Neste caso, o risco *a posteriori* é

$$\begin{aligned} R(a, x) &= E(L(a, \theta) | x) = \int_{-\infty}^{\infty} |a - \theta| \pi(\theta | x) d\theta \\ &= \int_{-\infty}^a (a - \theta) \pi(\theta | x) d\theta + \int_a^{\infty} (\theta - a) \pi(\theta | x) d\theta \\ &= a \int_{-\infty}^a \pi(\theta | x) d\theta - \int_{-\infty}^a \theta \pi(\theta | x) d\theta \\ &\quad + \int_a^{\infty} \theta \pi(\theta | x) d\theta - a \int_a^{\infty} \pi(\theta | x) d\theta \\ &= a F_{\theta | x}(a) - a [1 - F_{\theta | x}(a)] - \int_{-\infty}^a \theta \pi(\theta | x) d\theta \\ &\quad + \left[\int_{-\infty}^{\infty} \theta \pi(\theta | x) d\theta - \int_{-\infty}^a \theta \pi(\theta | x) d\theta \right] \\ &= 2a F_{\theta | x}(a) - a + E(\theta | x) - 2 \int_{-\infty}^a \theta \pi(\theta | x) d\theta \end{aligned} \quad (5)$$

Estimação Pontual como um problema de Decisão

Para encontrarmos a regra de Bayes, precisamos encontrar a ação a que minimiza o risco

$$R(a, \mathbf{x}) = 2aF_{\theta|\mathbf{x}}(a) - a + E(\theta | \mathbf{x}) - 2 \int_{-\infty}^a \theta \pi(\theta | \mathbf{x}) d\theta$$

Derivando $R(a, \mathbf{x})$ com respeito a a e igualando a zero temos:

$$\frac{d}{da} R(a, \mathbf{x}) = 2F_{\theta|\mathbf{x}}(a) + 2a\pi(a | \mathbf{x}) - 1 - 2a\pi(a | \mathbf{x}) = 2F_{\theta|\mathbf{x}}(a) - 1 = 0$$

$$\Rightarrow 2F_{\theta|\mathbf{x}}(a) = 1$$

Logo a ação ótima é escolher a tal que

$$F_{\theta|\mathbf{x}}(a) = 1/2 \Rightarrow a = F_{\theta|\mathbf{x}}^{-1}(1/2) \Rightarrow a = \text{Mediana}(\theta | \mathbf{x})$$

Note que

$$\frac{d^2}{da^2} R(a, \mathbf{x}) = 2\pi(a | \mathbf{x}) > 0 \quad (6)$$

Estimação Pontual: Aproximações Computacionais

Se tivermos uma amostra $\theta^{(1)}, \dots, \theta^{(n)}$ da distribuição *a posteriori* $\pi(\theta | x)$, podemos obter aproximações para os resumos da distribuição *a posteriori* de forma simples:

- Média e Variância *a posteriori*

$$E(\theta | X) \approx \sum_i \theta^{(i)} / n = \hat{\theta}$$

$$\text{Var}(\theta | X) \approx \sum_i (\theta^{(i)} - \hat{\theta})^2 / (n - 1)$$

- Mediana e a moda *a posteriori* podem ser aproximadas pela mediana e moda da amostra.

Estimação Pontual: Aproximações Computacionais

- ▶ Para a moda *a posteriori*, uma melhor aproximação é obtida utilizando-se a seguinte estratégia

$$Mo(\theta | X) \approx \max\{\text{Ker}(\pi(\theta^{(1)} | x)), \dots, \text{Ker}(\pi(\theta^{(n)} | x))\}.$$

- ▶ Para a mediana *a posteriori*
 - ▶ Agrupe os θ s e Identifique a classe $[PI, PF]$ que contém a mediana;
 - ▶ Uma aproximação razoável da mediana é dada por:

$$Md(\theta | x) \approx PI + \frac{(PF - PI)(0,5 - FA_{cam})}{(FA_{cm} - FA_{cam})}.$$

- ▶ Outra aproximação útil para a mediana: Obtenha as aproximações para a moda e média como descrito anteriormente e faça

$$Md(\theta | x) \approx \frac{2E(\theta | x) - Mo(\theta | x)}{3}$$

- ▶ Pode-se obter uma amostra da distribuição *a posteriori* de $g(\theta) \leftarrow g(\theta^{(1)}), \dots, g(\theta^{(n)})$.