

# Inferência Estatística com Abordagem Bayesiana

Rosangela Helena Loschi <sup>1</sup>

<sup>1</sup>Departamento de Estatística  
Universidade Federal de Minas Gerais

18 de novembro de 2021

# INFERÊNCIA NA FAMÍLIA NORMAL COM MÉDIA E VARIÂNCIA DESCONHECIDAS

## Inferência na família $N(\mu, \sigma^2)$

Consideremos o caso em que  $X_1, \dots, X_n$ , dado  $\mu$  e  $\sigma^2$ , são variáveis aleatórias i.i.d com distribuição Normal( $\mu, \sigma^2$ ), em que  $\mu$  e  $\sigma^2$  são desconhecidas.

Nossa meta é determinar

- ▶ a família conjugada natural
- ▶ a distribuição não informativa no Sentido Bayes-Laplace
- ▶ a distribuição não informativa no Sentido de Jeffreys.

Sob as suposições do problema temos que o núcleo da função de verossimilhança é

$$\begin{aligned} f(\mathbf{x} \mid \mu, \sigma^2) &= (2\pi\sigma^2)^{-n/2} \exp \left\{ \frac{-1}{2\sigma^2} \left( \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right) \right\} \\ &\propto \left( \frac{1}{\sigma^2} \right)^{n/2} \exp \left\{ \frac{-1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right\} \times \exp \left\{ -\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x}) \right\} \\ &\propto g(\sigma^2) \times h(\mu \mid \sigma^2) \end{aligned}$$

## Inferência na família $N(\mu, \sigma^2)$ : Conjugação

- ▶ Note que  $g(\sigma^2)$  é o núcleo de uma distribuição Gama-Invertida e  $h(\mu | \sigma^2)$  é o núcleo de uma distribuição normal.
- ▶ A fdp de  $\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d)$ ,  $a > 0, d > 0$  é

$$\pi(\sigma^2) = \frac{(a/2)^{d/2}}{\Gamma(d/2)} (\sigma^2)^{-\frac{d+2}{2}} \exp\left\{-\frac{a}{2\sigma^2}\right\}, \sigma^2 > 0.$$

- ▶ A esperança e variância de  $\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d)$  são, respectivamente,

$$E(\sigma^2) = \frac{a}{d-2}, \text{ se } d > 2$$

$$V(\sigma^2) = \frac{2a^2}{(d-2)^2(d-4)}, \text{ se } d > 4.$$

- ▶ Por construção, a família de distribuições para  $(\mu, \sigma^2)$  que é candidata a ser conjugada da família  $N(\mu, \sigma^2)$ ,  $(\mu, \sigma^2)$  desconhecidos é

$$\mu | \sigma^2 \sim \text{Normal}(m, V\sigma^2), m \in \mathbb{R}, V > 0 \quad (1)$$

$$\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d), a > 0, d > 0 \quad (2)$$

## Inferência na família $N(\mu, \sigma^2)$ : Conjugação

- ▶ Esta distribuição *a priori* impõe uma relação de dependência entre  $\mu$  e  $\sigma^2$
- ▶ Temos que verificar se é uma família fechada por produto.

Cálculo da distribuição *a posteriori* conjunta de  $(\mu, \sigma^2)$ :

$$\begin{aligned}\pi(\mu, \sigma^2 \mid \mathbf{x}) &\propto \left(\frac{1}{\sigma^2}\right)^{n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\right\} \exp\left\{-\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x})\right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp\left\{-\frac{1}{2V\sigma^2}(\mu^2 - 2\mu m + m^2)\right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{\frac{d+2}{2}} \exp\left\{-\frac{a}{2\sigma^2}\right\} \\ &\propto \left(\frac{1}{\sigma^2}\right)^{\frac{n+d+2}{2}} \exp\left\{-\frac{1}{2\sigma^2}\left(a + \sum_{i=1}^n x_i^2 + m^2/V\right)\right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp\left\{-\frac{1}{2V\sigma^2}(\mu^2 - 2\mu m) - \frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x})\right\}\end{aligned}$$

## Inferência na família $N(\mu, \sigma^2)$ : Conjugação

$$\begin{aligned}\pi(\mu, \sigma^2 \mid \mathbf{x}) &\propto \left(\frac{1}{\sigma^2}\right)^{\frac{n+d+2}{2}} \exp\left\{-\frac{1}{2\sigma^2}\left(a + \sum_{i=1}^n x_i^2 + m^2/V\right)\right\} \\&\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp\left\{-\frac{1}{2\sigma^2} \left[\mu^2(n+1/V) - 2\mu(n\bar{x} + m/V)\right]\right\} \\&\propto \left(\frac{1}{\sigma^2}\right)^{\frac{n+d+2}{2}} \exp\left\{-\frac{1}{2\sigma^2}\left(a + \sum_{i=1}^n x_i^2 + m^2/V\right)\right\} \\&\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp\left\{-\frac{1}{2\sigma^2} \left[\mu^2\left(\frac{nV+1}{V}\right) - 2\mu\left(\frac{nV\bar{x}+m}{V}\right)\right]\right\} \\&\propto \left(\frac{1}{\sigma^2}\right)^{\frac{n+d+2}{2}} \exp\left\{-\frac{1}{2\sigma^2}\left(a + \sum_{i=1}^n x_i^2 + m^2/V\right)\right\} \\&\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp\left\{-\frac{nV+1}{2V\sigma^2} \left[\mu^2 - 2\mu\frac{(nV\bar{x}+m)/V}{(nV+1)/V}\right]\right\}\end{aligned}$$

(4)

# Inferência na família $N(\mu, \sigma^2)$ : Conjugação

$$\pi(\mu, \sigma^2 \mid \mathbf{x})$$

$$\begin{aligned} &\propto \left(\frac{1}{\sigma^2}\right)^{\frac{n+d+2}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \left( a + \sum_{i=1}^n x_i^2 + m^2/V \right) + \frac{nV+1}{2V\sigma^2} \left( \frac{nV\bar{x}+m}{nV+1} \right)^2 \right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp \left\{ -\frac{nV+1}{2V\sigma^2} \left[ \mu^2 - 2\mu \frac{nV\bar{x}+m}{nV+1} + \left( \frac{nV\bar{x}+m}{nV+1} \right)^2 \right] \right\} \\ &\propto \left(\frac{1}{\sigma^2}\right)^{\frac{n+d+2}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \left( a + \sum_{i=1}^n x_i^2 + \frac{m^2}{V} - \frac{(nV\bar{x}+m)^2}{v(nV+1)} \right) \right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{\frac{1}{2}} \exp \left\{ -\frac{nV+1}{2V\sigma^2} \left[ \mu - \left( \frac{nV\bar{x}+m}{nV+1} \right) \right]^2 \right\} \end{aligned}$$

- ▶ Na expressão acima a parte azul é o núcleo de uma Gama-Inversa e a parte em vermelho é o núcleo de uma normal.
- ▶ Notamos o fechamento por produto da família de distribuições para  $(\mu, \sigma^2)$  que constituímos.

## Inferência na família $N(\mu, \sigma^2)$ : Conjugação

- Assim, a família de distribuições para  $(\mu, \sigma^2)$  que é conjugada natural da família de distribuições amostrais  $N(\mu, \sigma^2)$ , com ambos os parâmetros desconhecidos é:

$$\mu \mid \sigma^2 \sim N(m, V\sigma^2) \quad (5)$$

$$\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d) \quad (6)$$

- A distribuição *a posteriori* é

$$\mu \mid \sigma^2, \mathbf{x} \sim N\left(\frac{nV\bar{x} + m}{nV + 1}, \frac{V}{nV + 1}\sigma^2\right) = N(m^*, V^*\sigma^2)$$

$$\begin{aligned} \sigma^2 \mid \mathbf{x} &\sim \text{Gama} - \text{Inversa}\left(a + \sum_{i=1}^n x_i^2 + \frac{m^2}{V} - \frac{(nV\bar{x} + m)^2}{v(nV + 1)}, d + n\right) \\ &= \text{Gama} - \text{Inversa}(a^*, d^*) \end{aligned}$$



# Inferência na família $N(\mu, \sigma^2)$ : Conjugação

## Comentários relevantes:

Usando propriedades de Esperança e esperança condicional obtemos:

- ▶ A média e a variância *a posteriori* de  $\mu$

$$E(\mu | \mathbf{x}) = E_{\sigma^2 | \mathbf{x}}(E(\mu | \sigma^2, \mathbf{x})) = E_{\sigma^2 | \mathbf{x}}\left(\frac{nV\bar{x} + m}{nV + 1}\right) = \frac{nV\bar{x} + m}{nV + 1}$$

$$\begin{aligned} V(\mu | \mathbf{x}) &= E_{\sigma^2 | \mathbf{x}}(V(\mu | \sigma^2, \mathbf{x})) + V_{\sigma^2 | \mathbf{x}}(E(\mu | \sigma^2, \mathbf{x})) \\ &= \frac{V}{nV + 1}E(\sigma^2 | \mathbf{x}) + V\left(\frac{nV\bar{x} + m}{nV + 1}\right) = \frac{V}{nV + 1}E(\sigma^2 | \mathbf{x}) \end{aligned}$$

- ▶ A esperança *a posteriori* de  $\sigma^2$

$$E(\sigma^2 | \mathbf{x}) = \frac{a(d-2)}{(d-2)(d+n-2)} + \frac{nS^2}{d+n-2} + \frac{n(m+\bar{x})^2}{(d+n-2)(nV+1)}$$

onde  $S^2 = \sum_{i=1}^n (x_i - \bar{x})^2 / n$  é o EMV para  $\sigma^2$ .

# Inferência na família $N(\mu, \sigma^2)$ : Conjugação

## Comentários relevantes:

- ▶ Se  $n \rightarrow \infty$  (forte informação dos dados) segue que

$$\begin{aligned}E(\mu | \mathbf{x}) &\rightarrow \bar{x} \\V(\mu | \mathbf{x}) &\rightarrow 0 \\E(\sigma^2 | \mathbf{x}) &\rightarrow S^2\end{aligned}$$

- ▶ Se  $V \rightarrow \infty$  (informação vaga sobre  $\mu$ ) segue que

$$\begin{aligned}E(\mu | \mathbf{x}) &\rightarrow \bar{x} \\V(\mu | \mathbf{x}) &= \frac{1}{n} \lim_{V \rightarrow \infty} E(\sigma^2 | \mathbf{x}) \\E(\sigma^2 | \mathbf{x}) &\rightarrow \frac{d-2}{d+n-2} \frac{a}{d-2} + \frac{n}{d+n-2} S^2 \\&= \frac{d-2}{d+n-2} E(\sigma^2) + \frac{n}{d+n-2} S^2\end{aligned}$$

# Inferência na família $N(\mu, \sigma^2)$ : Conjugação

## Comentários relevantes:

- ▶ Se  $V \rightarrow \infty$ ,  $a \rightarrow 0$  e  $d \rightarrow 0$  (informação vaga sobre ambos  $\mu$  e  $\sigma^2$ ) segue que

$$E(\mu | \mathbf{x}) \rightarrow \bar{x}$$

$$V(\mu | \mathbf{x}) \rightarrow \frac{1}{n-2} S^2$$

$$E(\sigma^2 | \mathbf{x}) \rightarrow \frac{n}{n-2} S^2$$

- ▶ Se  $V = 0$  (informação contundente sobre  $\mu$ ) segue que

$$E(\mu | \mathbf{x}) = m$$

$$V(\mu | \mathbf{x}) = 0$$

$$E(\sigma^2 | \mathbf{x}) = \frac{(d-2)}{(d+n-2)} E(\sigma^2) + \frac{nS^2}{d+n-2} + \frac{n(m+\bar{x})^2}{(d+n-2)}$$

## Inferência na família $N(\mu, \sigma^2)$ : conjugação

Se, *a priori*, temos que

$$\mu \mid \sigma^2 \sim \text{Normal}(m, V\sigma^2), \quad m \in \mathbb{R}, V > 0 \quad (7)$$

$$\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d), \quad a > 0, d > 0, \quad (8)$$

- ▶ a distribuição *a priori* para  $\mu$  é uma distribuição *t*-Student ( $\mu \sim t(m, V, a, d)$ ) com fdp dada por:

$$\pi(\mu) = \left(\frac{1}{\pi}\right)^{1/2} \frac{\Gamma\left(\frac{d+1}{2}\right) a^{d/2}}{\Gamma\left(\frac{d}{2}\right) V^{1/2}} \left[a + \frac{(\mu - m)^2}{V}\right]^{-\frac{d+1}{2}}$$

- ▶ a média e variância *a priori* para  $\mu$  são

$$E(\mu) = m, \quad V(\mu) = \frac{aV}{d-2}$$

- ▶ O número de graus de liberdade é  $d$ .
- ▶ Como consequência da conjugação, *a posteriori*,  $\mu$  tem distribuição *t*-Student  $\mu \mid \mathbf{x} \sim t(m^*, V^*, a^*, d^*)$  (ver slide 8 para os parâmetros).

## A distribuição marginal de $\mu$

**FATO:** Suponha que

$$\mu \mid \sigma^2 \sim \text{Normal}(m, V\sigma^2), \quad m \in \mathbb{R}, V > 0 \quad (9)$$

$$\sigma^2 \sim \text{Gama} - \text{Inversa}(a, d), \quad a > 0, d > 0. \quad (10)$$

Prove que a distribuição marginal para  $\mu$  é uma distribuição  $t$ -Student ( $\mu \sim t(m, V, a, d)$ ) com fdp dada por:

$$\pi(\mu) = \left(\frac{1}{\pi}\right)^{1/2} \frac{\Gamma\left(\frac{d+1}{2}\right) a^{d/2}}{\Gamma\left(\frac{d}{2}\right) V^{1/2}} \left[a + \frac{(\mu - m)^2}{V}\right]^{-\frac{d+1}{2}}$$

- ▶ este é um resultado de Cálculo de probabilidade.
- ▶ Para prová-lo devemos lembrar que toda distribuição pode ser obtida integrando-se uma distribuição conjunta.

## A distribuição marginal de $\mu$

$$\begin{aligned}\pi(\mu) &= \int_0^\infty \pi(\mu | \sigma^2) \pi(\sigma^2) d\sigma^2 \\&= \int_0^\infty \left( \frac{1}{2\pi V \sigma^2} \right)^{1/2} \exp \left\{ -\frac{(\mu - m)^2}{2V \sigma^2} \right\} \\&\quad \times \frac{(a/2)^{d/2}}{\Gamma(d/2)} \left( \frac{1}{\sigma^2} \right)^{(d+2)/2} \exp \left\{ -\frac{a}{2\sigma^2} \right\} d\sigma^2 \\&= \frac{(a/2)^{d/2}}{\Gamma(d/2)} \left( \frac{1}{2\pi V} \right)^{1/2} \int_0^\infty \left( \frac{1}{\sigma^2} \right)^{\frac{d+3}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \left( a + \frac{(\mu - m)^2}{V} \right) \right\} d\sigma^2 \\&= \frac{(a/2)^{d/2}}{\Gamma(d/2)} \left( \frac{1}{2\pi V} \right)^{1/2} \frac{\Gamma\left(\frac{d+1}{2}\right)}{\left[ a + \frac{(\mu - m)^2}{V} \right]^{(d+1)/2} (1/2)^{(d+1)/2}} \\&= \left( \frac{1}{\pi} \right)^{1/2} \frac{\Gamma((d+1)/2)}{\Gamma(d/2)} \frac{(a/2)^{d/2}}{(2V)^{1/2}} 2^{(d+1)/2} \left[ a + \frac{(\mu - m)^2}{V} \right]^{-(d+1)/2} \\&= \left( \frac{1}{\pi} \right)^{1/2} \frac{\Gamma\left(\frac{d+1}{2}\right)}{\Gamma\left(\frac{d}{2}\right)} \frac{a^{d/2}}{V^{1/2}} \left[ a + \frac{(\mu - m)^2}{V} \right]^{-\frac{d+1}{2}}\end{aligned}$$

## Inferência na família $N(\mu, \sigma^2)$ : conjugação

Neste caso, a distribuição preditiva *a priori* para  $\mathbf{X} = (X_1, \dots, X_n)$  é obtida fazendo-se

$$f(\mathbf{X}) = \int_0^\infty \int_{-\infty}^\infty f(\mathbf{X} \mid \mu, \sigma^2) \pi(\mu \mid \sigma^2) \pi(\sigma^2) d\mu d\sigma^2.$$

Com isto, distribuição preditiva *a priori* para  $\mathbf{X} = (X_1, \dots, X_n)$  é uma distribuição *t*-student  $n$  variada denotada por:

$$\mathbf{X} \sim t_n(m\mathbf{1}_{n \times 1}, I_n + V\mathbf{1}_{n \times n}, d, a)$$

com grau de liberdade  $d$  e média e variância dada por:

$$E(\mathbf{X}) = m\mathbf{1}_{n \times 1} \quad V(\mathbf{X}) = \frac{a}{d-2}(I_n + V\mathbf{1}_{n \times n}),$$

onde  $I_n$  é a matriz identidade de ordem  $n$  e  $\mathbf{1}_{a \times b}$  denota uma matriz de uns de ordem  $a \times b$ .

# Inferência na família $N(\mu, \sigma^2)$ : Dist. de Bayes-Laplace

Neste caso,

- \* o espaço paramétrico é  $\mathbb{R} \times \mathbb{R}_+$ .
- \* a distribuição *a priori* não-informativa no sentido de Bayes-Laplace é  $\pi(\mu, \sigma^2) \propto 1, \forall (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+ \leftarrow$  é imprópria.
- Segue que o núcleo da distribuição *a posteriori* para  $(\mu, \sigma^2)$  é

$$\begin{aligned}\pi(\mu, \sigma^2 \mid \mathbf{x}) &\propto \left(\frac{1}{\sigma^2}\right)^{n/2} \exp\left\{\frac{-1}{2\sigma^2} \sum_{i=1}^n x_i^2\right\} \exp\left\{-\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x})\right\} \\ &\propto \left(\frac{1}{\sigma^2}\right)^{(n-1)/2} \exp\left\{\frac{-1}{2\sigma^2} \sum_{i=1}^n x_i^2\right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left\{-\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x})\right\}\end{aligned}\tag{11}$$



## Inferência na família $N(\mu, \sigma^2)$ : Dist. de Bayes-Laplace

$$\begin{aligned}\pi(\mu, \sigma^2 \mid \mathbf{x}) &\propto \left(\frac{1}{\sigma^2}\right)^{(n-1)/2} \exp\left\{\frac{-1}{2\sigma^2} \sum_{i=1}^n x_i^2\right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left\{-\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x} + \bar{x}^2 - \bar{x}^2)\right\} \\ &\propto \left(\frac{1}{\sigma^2}\right)^{(n-1)/2} \exp\left\{\frac{-1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2\right)\right\} \\ &\times \left(\frac{1}{\sigma^2}\right)^{1/2} \exp\left\{-\frac{n}{2\sigma^2} (\mu - \bar{x})^2\right\}\end{aligned}$$

## Inferência na família $N(\mu, \sigma^2)$ : Dist. de Bayes-Laplace

- A *posteriori*, temos que

$$\mu \mid \sigma^2, \mathbf{x} \sim \text{Normal}(\bar{x}, \sigma^2/n)$$

$$\sigma^2 \mid \mathbf{x} \sim \text{Gamma} - \text{Inversa} \left( \sum_{i=1}^n x_i^2 - n\bar{x}^2, n-3 \right)$$

- Note que a distribuição *a posteriori* de  $\sigma^2$  é própria somente se

$$\sum_{i=1}^n x_i^2 - n\bar{x}^2 = \sum_{i=1}^n (x_i - \bar{x})^2 > 0 \quad \text{e} \quad n > 3$$

- Isto impõe que devemos ter mais que 3 elementos na amostra.
- Além disto, se  $x_i = 0$  para todo  $i$ , teremos uma distribuição imprópria e não haverá inferência *a posteriori*.

## Dist. de Jeffreys: Método de Jeffreys

Se  $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$  existe dois métodos para encontrar a distribuição conjunta *a priori* de Jeffreys para  $\boldsymbol{\theta}$

### Método de Jeffreys:

- ▶ se  $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$ , a **Informação de Fisher** esperada é uma matriz  $I(\boldsymbol{\theta})$  dado por

$$I(\boldsymbol{\theta}) = E_{\mathbf{X}|\boldsymbol{\theta}} \left[ -\frac{\partial^2}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^T} \ln f(\mathbf{X} | \boldsymbol{\theta}) \right]$$

onde cada entrada  $ij$  da matriz  $I(\boldsymbol{\theta})$  é dada por:

$$I_{ij}(\boldsymbol{\theta}) = E_{\mathbf{X}|\boldsymbol{\theta}} \left[ -\frac{\partial^2}{\partial \theta_i \partial \theta_j} \ln f(\mathbf{X} | \boldsymbol{\theta}) \right]$$

- ▶ a distribuição conjunta *a priori* de Jeffreys para  $\boldsymbol{\theta}$  é

$$\pi(\boldsymbol{\theta}) \propto [\det I(\boldsymbol{\theta})]^{1/2}, \forall \boldsymbol{\theta} \in \Theta.$$

## Inferência na família $N(\mu, \sigma^2)$ : Método de Jeffreys

Como estamos considerando uma amostra iid da na família  $N(\mu, \sigma^2)$ , vamos calcular a informação de Fisher considerando apenas uma observação

- ▶ a verossimilhança

$$f(x | \mu, \sigma^2) = \left( \frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$

- ▶ o logaritmo da verossimilhança

$$\ln f = \ln f(x | \mu, \sigma^2) = -\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (x - \mu)^2$$

- ▶ as derivadas parciais

$$\begin{aligned} \frac{\partial \ln f}{\partial \mu} &= \frac{x - \mu}{\sigma^2} & \frac{\partial^2 \ln f}{\partial \mu^2} &= -\frac{1}{\sigma^2} \\ \frac{\partial \ln f}{\partial \sigma^2} &= -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2(\sigma^2)^2} & \frac{\partial^2 \ln f}{\partial (\sigma^2)^2} &= \frac{1}{2(\sigma^2)^2} - \frac{(x - \mu)^2}{(\sigma^2)^3} \\ \frac{\partial \ln f}{\partial \mu \partial \sigma^2} &= -\frac{x - \mu}{(\sigma^2)^2} \end{aligned}$$

## Inferência na família $N(\mu, \sigma^2)$ : Método de Jeffreys

- A matriz de informação de Fisher para  $\theta = (\mu, \sigma^2)$

$$\begin{aligned} I(\theta) &= \det E_{x|\mu, \sigma} \begin{bmatrix} \frac{1}{\sigma^2} & \frac{x-\mu}{(\sigma^2)^2} \\ \frac{x-\mu}{(\sigma^2)^2} & -\frac{1}{2(\sigma^2)^2} + \frac{(x-\mu)^2}{(\sigma^2)^3} \end{bmatrix} \\ &= \det \begin{bmatrix} E_{x|\mu, \sigma} \left( \frac{1}{\sigma^2} \right) & E_{x|\mu, \sigma} \left( \frac{x-\mu}{(\sigma^2)^2} \right) \\ E_{x|\mu, \sigma} \left( \frac{x-\mu}{(\sigma^2)^2} \right) & E_{x|\mu, \sigma} \left( -\frac{1}{2(\sigma^2)^2} + \frac{(x-\mu)^2}{(\sigma^2)^3} \right) \end{bmatrix} \\ &= \det \begin{bmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & E_{x|\mu, \sigma} \left( -\frac{1}{2(\sigma^2)^2} + \frac{(x-\mu)^2}{(\sigma^2)^3} \right) \end{bmatrix} \\ &= \det \begin{bmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \left( -\frac{1}{2(\sigma^2)^2} + \frac{\sigma^2}{(\sigma^2)^3} \right) \end{bmatrix} = \det \begin{bmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \left( \frac{1}{2(\sigma^2)^2} \right) \end{bmatrix} \\ &= \frac{1}{2(\sigma^2)^3} \end{aligned} \tag{12}$$

- A distribuição *a priori* de Jeffreys para  $(\mu, \sigma^2)$  é

$$\pi(\mu, \sigma^2) \propto \left( \frac{1}{\sigma^2} \right)^{3/2} \leftarrow \text{impropria}$$

## Inferência na família $N(\mu, \sigma^2)$ : Método de Jeffreys

- ▶ A distribuição *a posteriori* assumindo a distribuição *a priori* de Jeffreys é

$$\begin{aligned}\mu \mid \sigma^2, \mathbf{x} &\sim N\left(\bar{x}, \frac{\sigma^2}{n}\right) \\ \sigma^2 \mid \mathbf{x} &\sim \text{Gama} - \text{Inversa}\left(\sum_{i=1}^n (x_i - \bar{x})^2, n\right)\end{aligned}\quad (13)$$

- ▶ É uma distribuição própria sempre que  $n > 0$  e  $\sum_{i=1}^n (x_i - \bar{x})^2 > 0$ .
- ▶ Como no caso anterior, se  $x_i = 0$  para todo  $i$ , não teremos inferência *a posteriori* pois tal distribuição será imprópria.

# Dist. de Jeffreys: Método Jeffreys-Independente

Método Jeffreys-Independente: seja  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p) \in \Theta \subset \mathbb{R}^p$

- ▶ Assume-se que  $\theta_1, \dots, \theta_p$  são independentes
- ▶ Encontre a distribuição *a priori*  $\pi(\theta_i)$  de cada  $\theta_i$  considerando os demais  $\theta$ s conhecidos.
- ▶ A distribuição *a priori* de Jeffreys para  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)$  é

$$\pi(\boldsymbol{\theta}) \propto \pi(\theta_1) \dots \pi(\theta_p)$$

# Inferência na família $N(\mu, \sigma^2)$ : Dist. de Jeffreys-independente

Estamos considerando uma amostra iid da família  $N(\mu, \sigma^2)$ .

- ▶ assuma  $\mu$  independente de  $\sigma^2$ .
- ▶ a verossimilhança

$$f(x | \mu, \sigma^2) = \left( \frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$

- ▶ o logaritmo da verossimilhança

$$\ln f = \ln f(x | \mu, \sigma^2) = -\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (x - \mu)^2$$

- ▶ Informação de Fisher para  $\mu$

$$\begin{aligned} \frac{d \ln f}{d\mu} &= \frac{x - \mu}{\sigma^2} & \frac{d^2 \ln f}{d\mu^2} &= -\frac{1}{\sigma^2} \\ I(\mu) &= \frac{1}{\sigma^2} \leftarrow \text{constante} \end{aligned}$$

- ▶ A distribuição de Jeffreys para  $\mu$

$$\pi(\mu) \propto 1$$



## Inferência na família $N(\mu, \sigma^2)$ : Dist. de Jeffreys-independente

- ▶ A informação de Fisher para  $\sigma^2$

$$\begin{aligned}\frac{d \ln f}{d \sigma^2} &= -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2(\sigma^2)^2} & \frac{d^2 \ln f}{d(\sigma^2)^2} &= \frac{1}{2(\sigma^2)^2} - \frac{(x - \mu)^2}{(\sigma^2)^3} \\ I(\sigma^2) &= E_{x|\mu, \sigma} \left( -\frac{1}{2(\sigma^2)^2} + \frac{(x - \mu)^2}{(\sigma^2)^3} \right) = \frac{1}{2(\sigma^2)^2} \quad (14)\end{aligned}$$

- ▶ A distribuição de Jeffreys para  $\sigma^2$  é

$$\pi(\sigma^2) \propto \left( \frac{1}{2(\sigma^2)^2} \right)^{1/2} \propto \frac{1}{\sigma^2} \leftarrow \text{impropria}$$

- ▶ A **distribuição de Jeffreys conjunta** para  $(\mu, \sigma^2)$  usando o método Jeffreys-independente é

$$\pi(\mu, \sigma^2) = \pi(\mu)\pi(\sigma^2) \propto \frac{1}{\sigma^2} \leftarrow \text{impropria}$$

- ▶ é a distribuição não-informativa mais utilizada no caso da família Normal com média e variâncias desconhecidas.

## Dist. de Jeffreys: Método Jeffreys-Independente

- ▶ A distribuição *a posteriori* conjunta assumindo a distribuição *a priori* Jeffreys-independente é

$$\begin{aligned}\mu \mid \sigma^2, \mathbf{x} &\sim N(\bar{x}, \sigma^2/n) \\ \sigma^2 \mid \mathbf{x} &\sim \text{Gama - Inversa} \left( \sum_{i=1}^n (x_i - \bar{x})^2, n-1 \right)\end{aligned}\quad (15)$$

- ▶ É própria desde que  $n > 1$  e  $\sum_{i=1}^n (x_i - \bar{x})^2 > 0$ .

## O Que leva o método Jeffreys-independente à popularidade?

Consideremos o caso em que  $X_1, \dots, X_n$ , dado  $\mu$  e  $\sigma^2$ , são variáveis aleatórias i.i.d com distribuição Normal( $\mu, \sigma^2$ ), em que  $\mu$  e  $\sigma^2$  são desconhecidas.

Método de Jeffreys:

- ▶ A distribuição *a priori* de Jeffreys para  $(\mu, \sigma^2)$  é

$$\pi(\mu, \sigma^2) \propto \left(\frac{1}{\sigma^2}\right)^{3/2}$$

- ▶ A distribuição *a posteriori* assumindo a distribuição *a priori* de Jeffreys é

$$\begin{aligned}\mu \mid \sigma^2, \mathbf{x} &\sim N\left(\bar{x}, \frac{\sigma^2}{n}\right) \\ \sigma^2 \mid \mathbf{x} &\sim \text{Gama-Inversa}\left(\sum_{i=1}^n (x_i - \bar{x})^2, n\right)\end{aligned}\quad (16)$$

- ▶ Desta distribuição *a posteriori* decorre que

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2} \mid \mathbf{x} \sim \chi_{(n)}^2$$

## O Que leva o método Jeffreys-independente à popularidade?

Consideremos agora o caso em que  $X_1, \dots, X_n$ , dado  $\sigma^2$ , são variáveis aleatórias i.i.d com distribuição Normal( $\mu, \sigma^2$ ), em que  $\sigma^2$  é desconhecido e  $\mu$  é conhecido.

- ▶ A dist. *a priori* de Jeffreys para  $\sigma^2$  é

$$\pi(\sigma^2) \propto \left( \frac{1}{\sigma^2} \right)$$

- ▶ A dist. *a posteriori* assumindo a dist. *a priori* de Jeffreys é

$$\sigma^2 \mid \mathbf{x} \sim \text{Gama} - \text{Inversa} \left( \sum_{i=1}^n (x_i - \mu)^2, n \right)$$

- ▶ Desta distribuição *a posteriori* decorre que

$$\frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2} \mid \mathbf{x} \sim \chi_{(n)}^2$$

- ▶ O método de Jeffreys fornece uma dist. *a priori* conjunta para  $(\mu, \sigma^2)$  que induz uma dist. *a posteriori* para  $\sigma^2$  que é insensível ao fato da média populacional  $\mu$  ser ou não conhecida.

## O Que leva o método Jeffreys-independente à popularidade?

Suponha que  $X_1, \dots, X_n$ , dado  $\mu$  e  $\sigma^2$ , são variáveis aleatórias i.i.d com distribuição Normal( $\mu, \sigma^2$ ), com  $\mu$  e  $\sigma^2$  **são desconhecidas**.

**Método Jeffreys-independente:**

- ▶ A distribuição *a priori* de Jeffreys para  $(\mu, \sigma^2)$  é  $\pi(\mu, \sigma^2) \propto \frac{1}{\sigma^2}$
- ▶ A distribuição *a posteriori* conjunta assumindo a distribuição *a priori* Jeffreys-independente é

$$\begin{aligned}\mu \mid \sigma^2, \mathbf{x} &\sim N(\bar{x}, \sigma^2/n) \\ \sigma^2 \mid \mathbf{x} &\sim \text{Gama-Inversa} \left( \sum_{i=1}^n (x_i - \bar{x})^2, n-1 \right)\end{aligned} \quad (17)$$

- ▶ Desta distribuição *a posteriori* decorre que

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2} \mid \mathbf{x} \sim \chi^2_{(n-1)}$$

- ▶ O Método Jeffreys-independente fornece uma distribuição *a priori* conjunta para  $(\mu, \sigma^2)$  que induz uma distribuição *a posteriori* para  $\sigma^2$  que é sensível ao fato da média populacional  $\mu$  ser desconhecida.