

# Inferência Estatística com Abordagem Bayesiana

Rosangela Helena Loschi <sup>1</sup>

<sup>1</sup>Departamento de Estatística  
Universidade Federal de Minas Gerais

25 de outubro de 2021

# MÉTODOS DE CONSTRUÇÃO DA DISTRIBUIÇÃO *A PRIORI*

- ▶ **Distribuições conjugadas naturais**
- ▶ Distribuições de referências: Métodos Bayes-Laplace e Jeffreys

# Distribuições Conjugadas

Quando decidimos fazer uma **análise conjugada** dos dados estamos buscando por

- (1) Simplicidade na derivação da distribuição *a posteriori*.
- (2) Parâmetros interpretáveis *a posteriori*

sem perdermos a versatilidade em acomodar opiniões *a priori* de diferentes pessoas que, eventualmente, têm informações iniciais muito distintas.

**Conjugação é uma propriedade de famílias de distribuições.**

Se dois indivíduos decidem fazer uma análise conjugada do mesmo problema,

- ▶ suas distribuições *a priori* pertencerão à mesma família;
- ▶ no entanto, estas distribuições podem ser diferentes, dependendo do conhecimento inicial que têm.

## Distribuições Conjugadas

**Definição de Conjugação natural:** Seja  $\mathcal{F}$  uma família de distribuições amostrais indexadas pelo parâmetro  $\theta$ , isto é,

$$\mathcal{F} = \{f(x | \theta) : \theta \in \Theta, x \in \mathcal{X}\}.$$

Seja  $\mathcal{P}$  uma família de distribuições de probabilidade definida no espaço paramétrico  $\Theta$ ,

$$\mathcal{P} = \{\pi(\theta | a) : a \in \mathcal{A}\},$$

onde  $\mathcal{A}$  é um conjunto de hiperparâmetros. Dizemos que as famílias  $\mathcal{F}$  e  $\mathcal{P}$  são **famílias conjugadas naturais** se

- (i)  $\mathcal{P}$  é fechada sob a amostragem de  $\mathcal{F}$ , ou seja, se  $f(x | \theta) \in \mathcal{F}$  é proporcional a um membro de  $\mathcal{P}$ , para cada  $x \in \mathcal{X}$ .
- (ii)  $\mathcal{P}$  é fechada com respeito ao produto, ou seja, para todo  $a_0, a_1 \in \mathcal{A}$ , existe  $a_2$  tal que

$$\pi(\theta | a_0)\pi(\theta | a_1) = \pi(\theta | a_2) \in \mathcal{P}.$$

# Distribuições Conjugadas

Como consequência, se estamos fazendo uma análise conjugada

- ▶ a verossimilhança, se a vemos como uma função de  $\theta$ , é proporcional à distribuição *a priori*
- ▶ as distribuições *a priori* e *a posteriori* pertencem à mesma família de distribuições.

A subjetividade na especificação da distribuição *a priori* ainda existe. Perceba que para um mesmo problema


- ▶ A família de distribuição *a priori* é a mesma para todos aqueles que fazem a análise conjugada.
- ▶ A subjetividade está na especificação dos hiperparâmetros  $a$ , que dependerá do conhecimento prévio cada um tem sobre o parâmetro.

## Distribuições Conjugadas: Caso Beta-Bernoulli

Se  $X_1, \dots, X_n$ , dado  $\theta$ , são i.i.d com distribuição Bernoulli( $\theta$ ) e se, a priori,  $\theta \sim \text{Beta}(\alpha, \beta)$ , então a posteriori,  $\theta \mid \mathbf{x} \sim \text{Beta}(\alpha + \sum_{i=1}^n x_i, \beta + n - \sum_{i=1}^n x_i)$ .

**Solução:** Iniciemos encontrando a função de verossimilhança. Como, dado  $\theta$ ,  $X_1, \dots, X_n$  são i.i.d temos que, para todo  $x_i \in \{0, 1\}, i = 1, \dots, n$ ,

$$\begin{aligned} f(x_1, \dots, x_n \mid \theta) &= \prod_{i=1}^n f(x_i \mid \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \\ &= \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \end{aligned}$$



# Distribuições Conjugadas: Caso Beta-Bernoulli

A distribuição preditiva *a priori*

$$\begin{aligned}f(\mathbf{x}) &= f(x_1, \dots, x_n) = \int_0^1 f(\mathbf{x} \mid \theta) \pi(\theta) d\theta \\&= \int_0^1 \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \times \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} d\theta \\&= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 \theta^{\alpha + \sum_{i=1}^n x_i - 1} (1 - \theta)^{\beta + n - \sum_{i=1}^n x_i - 1} d\theta \\&= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha + \sum_{i=1}^n x_i) \Gamma(\beta + n - \sum_{i=1}^n x_i)}{\Gamma(\alpha + \beta + n)}\end{aligned}\tag{1}$$

para todo  $x_i \in \{0, 1\}, i = 1, \dots, n$ .

# Distribuições Conjugadas: Caso Beta-Bernoulli

A distribuição *a posteriori* para  $\theta \in (0, 1)$



$$\begin{aligned}f(\theta \mid x_1, \dots, x_n) &= \frac{f(\mathbf{x} \mid \theta)\pi(\theta)}{f(\mathbf{x})} \\&= \frac{\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha+\sum_{i=1}^n x_i-1} (1-\theta)^{\beta+n-\sum_{i=1}^n x_i-1} d\theta}{\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha+\sum_{i=1}^n x_i)\Gamma(\beta+n-\sum_{i=1}^n x_i)}{\Gamma(\alpha+\beta+n)}} \\&= \frac{\Gamma(\alpha+\beta+n)}{\Gamma(\alpha+\sum_{i=1}^n x_i)\Gamma(\beta+n-\sum_{i=1}^n x_i)} \\&\times \theta^{\alpha+\sum_{i=1}^n x_i-1} (1-\theta)^{\beta+n-\sum_{i=1}^n x_i-1}\end{aligned}$$

Logo,  $\theta \mid \mathbf{x} \sim \text{Beta}(\alpha + \sum_{i=1}^n x_i, \beta + n - \sum_{i=1}^n x_i)$ .



# Distribuições Conjugadas: Caso Beta-Bernoulli

Assumindo que  $\theta \sim \text{Unif}(0, 1) \equiv \text{Beta}(1, 1)$  e observando as amostras  $(0, 1)$  e  $(1, 1)$  temos



# Distribuições Conjugadas: Caso Beta-Bernoulli

Neste caso,



- ▶ a distribuição *a priori* é não informativa: não discrimina nenhum valor que  $\theta$ .
- ▶ a verossimilhança discrimina valores de  $\theta$  próximos de 1 se a amostra observada é (1, 1) e discrimina valores próximos de 0,5 se a amostra observada é (0, 1).
- ▶ a informação dada pela distribuição *a posteriori* concorda com a informação dada pela verossimilhança: Os valores de  $\theta$  mais prováveis *a posteriori* são valores acima de 0.7 se a amostra observada é (1, 1) e estão entre 0.3 e 0.7 se a amostra observada é (0, 1)
- ▶ *A priori*,  $E(\theta) = 1/2$  e  $Var(\theta) = 1/12$ . Se observamos a amostra (0, 1) então  $\theta \mid x_1 = 0, x_2 = 1 \sim Beta(2, 2)$ . Assim, temos

$$E(\theta \mid x_1 = 0, x_2 = 1) = 1/2$$

$$Var(\theta \mid x_1 = 0, x_2 = 1) = 1/20$$

# Distribuições Conjugadas: Caso Beta-Bernoulli

Assumindo que  $\theta \sim \text{Beta}(1, 2)$  e observando as amostras (0, 1) e (1, 1) temos



# Distribuições Conjugadas: Caso Beta-Bernoulli

Neste caso,

- ▶ a distribuição *a priori* coloca mais massa probabilística para valores de  $\theta$  próximos de zero.
- ▶ a verossimilhança discrimina valores de  $\theta$  próximos de 1 se a amostra observada é (1, 1) e discrimina valores próximos de 0,5 se a amostra observada é (0, 1).
- ▶ a distribuição *a priori* e a função de verossimilhança fornecem informações conflitantes sobre  $\theta$ , principalmente, se a amostra observada é (1, 1).
- ▶ Neste caso, quando misturamos as informações *a priori* e amostral sobre  $\theta$ , obtemos uma informação *a posteriori* sobre  $\theta$  bem modificada.
- ▶ a distribuição *a posteriori* sobre  $\theta$  tende a estar mais próxima da informação trazida pelos dados pois a distribuição *a priori* é fraca (tem uma variância grande)

# Distribuições Conjugadas: Caso Beta-Bernoulli

- ▶ Neste exemplo, se pode perceber o processo de atualização da informação sobre  $\theta$  mais claramente.
- ▶ Como  $\theta \mid \mathbf{x} \sim \text{Beta}(\alpha + \sum_{i=1}^n x_i, \beta + n - \sum_{i=1}^n x_i)$ , a média *a posteriori* é

$$\begin{aligned} E(\theta \mid \mathbf{x}) &= \frac{\alpha + \sum_{i=1}^n x_i}{(\alpha + \sum_{i=1}^n x_i) + (\beta + n - \sum_{i=1}^n x_i)} \\ &= \frac{\alpha + \sum_{i=1}^n x_i}{\alpha + \beta + n} \\ &= \frac{\alpha + \beta}{\alpha + \beta + n} E(\theta) + \frac{n}{\alpha + \beta + n} \bar{X} \end{aligned}$$

- ▶  $E(\theta \mid \mathbf{x})$  é uma combinação linear convexa da média *a priori* e do estimador de máxima verosimilhança para  $\theta$ .

# Distribuições Conjugadas: Caso Beta-Bernoulli

Perceba que

- ▶ Se  $n \rightarrow \infty \Rightarrow E(\theta | x) \rightarrow \bar{X}$ : informação amostral é forte e domina a informação *a priori*.
- ▶ Se  $\alpha \rightarrow 0$  e  $\beta \rightarrow 0 \Rightarrow E(\theta | x) \rightarrow \bar{X}$ : informação *a priori* fraca e "qualquer" que seja a informação amostral ela dominará a distribuição *a priori*.

Denote por  $\omega = \frac{n}{\alpha + \beta + n}$  o peso que se atribui à informação dos dados.

## Distribuições Conjugadas: Caso Beta-Bernoulli

**Efeito do tamanho amostral** Suponha que o verdadeiro valor de  $\theta$  é 0.6 e que *a priori* assumimos que  $\theta \sim \text{Beta}(5, 45)$ . Note que nos sa inferência *a priori* está muito longe do verdadeiro  $\theta$  pois  $E(\theta) = 0.1$ . Suponha também que tenhamos gerado amostras de diferentes tamanhos ( $n = 5, 100, 1000, 10000$ ) de uma Bernoulli(0.6) e que observamos 60% de sucessos em todas as amostras geradas


Table: Médias *a posteriori*

$n$	Distr. Post.	$E(\theta)$	EMV	$\omega$	$E(\theta   x)$	$V(\theta   x)$
5	Beta(8, 47)	0.1	0.6	0.0909	0.1454	$2.22 \times 10^{-3}$
100	Beta(65, 85)			0.6667	0.4334	$1.63 \times 10^{-3}$
1000	Beta(605, 445)			0.9524	0.5762	$2.32 \times 10^{-4}$
10000	Beta(6005, 4045)			0.9950	0.5975	$2.39 \times 10^{-5}$

Quando maior o tamanho da amostra, menor é a influência da distribuição *a priori* na inferência *a posteriori*.

# Distribuições Conjugadas: Caso Beta-Bernoulli

Figure: Distribuciones *a posteriori*





# Distribuições Conjugadas: Caso Beta-Bernoulli

**Efeito da distribuição *a priori* 1:** Assuma que o verdadeiro valor de  $\theta$  é 0.6 e que eliciamos distintas distribuições *a priori* para  $\theta$ . Suponha que geramos uma amostra de tamanho  $n = 5$  de uma Bernoulli(0.6) e que observamos 60% de sucessos na amostra gerada.

Table: Médias *a posteriori*


Dist. Priori	Dist. Post.	$E(\theta)$	$V(\theta)$	EMV	$1 - \omega$	$E(\theta x)$	$V(\theta x)$
<i>Beta</i> (1, 1) – <i>vaga</i>	<i>Beta</i> (4, 3)	0.5	0,0833	0.6	0.2857	0.5714	0,0306
<i>Beta</i> (5, 5)	<i>Beta</i> (8, 7)	0.5	0,0227		0.6667	0.5333	0,0156
<i>Beta</i> (5, 45)	<i>Beta</i> (8, 47)	0.1	0,0015		0.9091	0.1454	0,0022
<i>Beta</i> (1, 9) – <i>vaga</i>	<i>Beta</i> (4, 11)	0.1	0,0082		0.6667	0.2666	0,0122

Neste caso,

- ▶ a informação dos dados estimam  $\theta$  perfeitamente.
- ▶ Todas as distribuições *a priori* subestimam  $\theta = 0.6$ .
- ▶ melhor inferência *a posteriori* é obtida se *a priori*  $\theta \sim \text{Unif}(0, 1)$ .
- ▶ Quando as informações amostral e *a priori* são **discordantes** ocorre um aumento na variância *a posteriori* se comparado com a variância *a priori*. Se são informações concordantes, a variância *a posteriori* diminui.

# Distribuições Conjugadas: Caso Beta-Bernoulli

Figure: Distribuciones *a posteriori*



Sempre devemos utilizar distribuições a priori vagas ou não informativas?

# Distribuições Conjugadas: Caso Beta-Bernoulli

**Efeito da distribuição *a priori* 2:** Se o verdadeiro valor de  $\theta$  é 0.5 e se eliciamos distintas distribuições *a priori* para  $\theta$ . Suponha que geramos uma amostra de tamanho  $n = 10$  de uma Bernoulli(0.5) e que observamos 60% de sucessos na amostra gerada.

Table: Médias *a posteriori*

Distr. Priori	Distr. Post.	$E(\theta)$	EMV	$1 - \omega$	$E(\theta   x)$
Beta(1, 1)-vaga	Beta(7, 5)	0.5	0.6	0.1667	0.5833
Beta(50, 50)	Beta(56, 54)			0.9091	0.5090
Beta(1, 9)-vaga	Beta(6.1, 6.4)	0.1		0.0909	0.5545
Beta(5, 45)	Beta(11, 49)			0.8334	0.1833

Note que

- ▶ a informação dos dados levam a superestimação de  $\theta$
- ▶ as distribuições *a priori* Beta(1, 1) (vaga) e Beta(50, 50) (muito informativa) levam a estimativas (Médias *a priori*) perfeitas de  $\theta$ .
- ▶ Sob tais distribuições *a priori*, a distribuição mais informativa leva a melhor estimativa *a posteriori*
- ▶ No caso de distribuições *a priori* que subestimam  $\theta$ , a melhor estimativa *a posteriori* é obtida sob a distribuição mais vaga

# Distribuições Conjugadas: Caso Beta-Bernoulli

## DISCUSSÕES IMPORTANTES: Obviamente,

- ▶ a distribuição *a priori* influencia a inferência *a posteriori*.
- ▶ Assim, ela deve traduzir adequadamente o seu conhecimento inicial sobre  $\theta$ .
- ▶ as distribuições *a priori* pouco informativas nem sempre conduzem às melhores inferências.
- ▶ a distribuição *a priori* é dominada pelos dados se
  - + a amostra é grande.
  - + a distribuição *a priori* é pouco informativa.

# Distribuições Conjugadas: Caso Beta-Bernoulli

## DISCUSSÕES IMPORTANTES:

- ▶ Na construção da verossimilhança utilizamos o conceito de **independência condicional**, isto é, assumimos que  $X_1$  é independente de  $X_2$ , dado  $\theta$ , isto é,

$$f(X_1, X_2 | \theta) = f(X_1 | \theta)f(X_2 | \theta)$$

. Podemos dizer que  $X_1$  é independente de  $X_2$ ?

- ▶ Dado  $\theta$ ,  $X_1$  e  $X_2$  são independentes  $\Rightarrow \text{Cov}(X_1, X_2 | \theta) = 0$ . Além disto,  $E(X_i | \theta) = \theta$ ,  $i = 1, 2$ . Daí, usando propriedades de covariância condicional, temos

$$\begin{aligned}\text{Cov}(X_1, X_2) &= E(\text{Cov}(X_1, X_2 | \theta)) + \text{COV}(E(X_1 | \theta), E(X_2 | \theta)) \\ &= E(0) + \text{Cov}(\theta, \theta) = \text{Var}(\theta).\end{aligned}\tag{2}$$

- ▶  $X_1$  e  $X_2$  são correlacionadas  $\Rightarrow X_1$  e  $X_2$  não são independentes.

## Distribuições Conjugadas: Caso Beta-Bernoulli

**Moda da distribuição  $Beta(\alpha, \beta)$ :** Consideremos o logaritmo da densidade de  $\theta$

$$\ln \pi(\theta) = \ln \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} + (\alpha - 1) \ln \theta + (\beta - 1) \ln(1 - \theta)$$

Se  $\theta$  é um ponto no interior do intervalo  $(0, 1)$ , derivando com respeito a  $\theta$  e igualando a zero, temos

$$\begin{aligned} \frac{d \ln \pi(\theta)}{d\theta} &= \frac{(\alpha - 1)}{\theta} + \frac{(\beta - 1)}{1 - \theta} = 0 \\ \Rightarrow (\alpha - 1) &= \theta(\alpha + \beta - 2) \end{aligned}$$

**Se  $\alpha + \beta \neq 2 \Rightarrow \hat{\theta} = \frac{(\alpha-1)}{(\alpha+\beta-2)}$**   $\leftarrow$  candidato a Máximo.

Considerando a segunda derivada com respeito a  $\theta$ , temos

$$\frac{d^2 \ln \pi(\theta)}{d\theta^2} = -\frac{(\alpha - 1)}{\theta^2} - \frac{(\beta - 1)}{(1 - \theta)^2}$$

(3)

## Distribuições Conjugadas: Caso Beta-Bernoulli

Avaliando a segunda derivada em  $\hat{\theta}$  temos

$$\frac{d^2 \ln \pi(\theta)}{d\theta^2} = - \left[ \frac{(\alpha + \beta - 2)^2}{\alpha - 1} + \frac{(\alpha + \beta - 2)^2}{\beta - 1} \right]$$

- ▶ se  $\alpha \leq 1$  e  $\beta \leq 1 \Rightarrow \frac{d^2 \ln \pi(\theta)}{d\theta^2} > 0 \Rightarrow$  não há ponto de máximo (moda)
- ▶ se  $\alpha > 1$  e  $\beta > 1 \Rightarrow \frac{d^2 \ln \pi(\theta)}{d\theta^2} < 0 \Rightarrow$  há moda e ela é

$$\hat{\theta} = \frac{(\alpha - 1)}{(\alpha + \beta - 2)}$$

- ▶ Para os demais valores de  $\alpha$  e  $\beta$  caso tem-se que fazer a análise. Pode ou não haver moda.
- ▶ A moda pode estar nos extremos. Por exemplo, se  $\alpha = 2$  e  $\beta = 1$  então  $\pi(\theta) = 2\theta \leftarrow$  função estritamente crescente com moda (máximo em)  $\hat{\theta} = 1$ .

## Dist. Conjugadas: Caso Normal com variância conhecida

**Exemplo:** Se  $X_1, \dots, X_n$ , dado  $\mu$ , são variáveis aleatórias i.i.d com distribuição  $\text{Normal}(\mu, \sigma^2)$ , em que a variância  $\sigma^2$  é conhecida.

Construa a família conjugada para o parâmetro  $\mu$ . Temos que

- \* o espaço paramétrico é  $\mathbb{R}$ .
- \* a função de verossimilhança é

$$\begin{aligned} f(\mathbf{x} \mid \mu) &= (2\pi\sigma^2)^{-n/2} \exp \left\{ \frac{-1}{2\sigma^2} \left( \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right) \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ \frac{-1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right\} \\ &\times \exp \left\{ \frac{-1}{2\sigma^2} \left( -2\mu \sum_{i=1}^n x_i + n\mu^2 \right) \right\} \\ &\propto \exp \left\{ -\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x}) \right\} \\ &\propto \exp \left\{ -\frac{n}{2\sigma^2} (\mu - \bar{x})^2 \right\} \end{aligned} \tag{4}$$



# Dist. Conjugadas: Caso Normal com variância conhecida

## O fechamento por amostragem:

- ▶ Olhando para a verossimilhança como uma função de  $\mu$  nos sugere que o núcleo da família de distribuições sobre  $\mu$  que é fechada sob a amostragem da família normal com  $\sigma^2$  conhecido deve ser

$$\pi(\mu) \propto \exp \left\{ -\frac{1}{2V}(\mu - M)^2 \right\}$$

- ▶ Por construção, temos que a família  $\mu \sim \text{Normal}(M, V)$  de distribuições sobre  $\mu$  é fechada sob a amostragem da família amostral normal com variância conhecida.
- ▶ Esta família é fechada por produto?

## Dist. Conjugadas: Caso Normal com variância conhecida

O fechamento por produto:

Assuma que, *a priori*  $\mu \sim \text{Normal}(M, V)$ . Assim,

$$\pi(\mu) \propto \exp \left\{ -\frac{1}{2V}(\mu - M)^2 \right\} = \exp \left\{ -\frac{1}{2V}(\mu^2 - 2\mu M) \right\} \exp \left\{ -\frac{1}{2V}M^2 \right\}$$

Misturando esta informação *a priori* com a verossimilhança em (4) temos que o núcleo da distribuição *a posteriori* para  $\mu$  é

$$\begin{aligned} \pi(\mu | x) &\propto \exp \left\{ -\frac{1}{2V}(\mu^2 - 2\mu M) \right\} \exp \left\{ -\frac{n}{2\sigma^2}(\mu^2 - 2\mu \bar{x}) \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left[ \mu^2 \left( \frac{1}{V} + \frac{n}{\sigma^2} \right) - 2\mu \left( \frac{M}{V} + \frac{n\bar{x}}{\sigma^2} \right) \right] \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left[ \mu^2 \left( \frac{\sigma^2 + nV}{V\sigma^2} \right) - 2\mu \left( \frac{M\sigma^2 + nV\bar{x}}{V\sigma^2} \right) \right] \right\} \\ &\propto \exp \left\{ -\left( \frac{\sigma^2 + nV}{2V\sigma^2} \right) \left[ \mu^2 - 2\mu \left( \frac{M\sigma^2 + nV\bar{x}}{\sigma^2 + nV} \right) \right] \right\} \end{aligned} \quad (5)$$

## Dist. Conjugadas: Caso Normal com variância conhecida

Ou seja,

- ▶ a distribuição *a posteriori*

$$\mu \mid \mathbf{x} \sim \text{Normal} \left( \frac{M\sigma^2 + nV\bar{x}}{\sigma^2 + nV}; \frac{V\sigma^2}{\sigma^2 + nV} \right) \quad (6)$$

- ▶ A família de distribuições para  $\mu$  dada em (5) é fechada por produto.
- ▶ Temos **conjugação natural**.

## Dist. Conjugadas: Caso Normal com variância conhecida

### IMPORTANTE:

- ▶ A média *a posteriori* é uma combinação linear convexa da média *a priori* com o EMV de  $\mu$

$$E(\mu | \mathbf{x}) = M \frac{\sigma^2}{\sigma^2 + nV} + \bar{x} \frac{nV}{\sigma^2 + nV} \quad (7)$$

- ▶ Perceba que se  $n \rightarrow \infty$ 
  - ▶  $E(\mu | \mathbf{x}) \rightarrow \bar{X}$ : informação amostral é forte e domina a informação *a priori*.
  - ▶  $Var(\mu | \mathbf{x}) \rightarrow 0$
  - ▶ Ou seja, a distribuição *a posteriori* de  $\mu$  converge para uma distribuição degenerada tal que  $P(\mu = \bar{x} | \mathbf{x}) = 1$
- ▶ Perceba que Se  $V \rightarrow \infty$ 
  - ▶  $E(\mu | \mathbf{x}) \rightarrow \bar{X}$ : a informação *a priori* fraca e "qualquer" que seja a informação amostral ela dominará a distribuição *a priori*. temos uma distribuição *a priori* vaga.
  - ▶  $Var(\mu | \mathbf{x}) \rightarrow \sigma^2/n$
  - ▶ Ou seja, a distribuição *a posteriori* de  $\mu$  converge para uma distribuição Normal( $\bar{x}, \sigma^2/n$ ).

## Dist. Conjugadas: Caso Normal com variância conhecida

### IMPORTANTE:

- ▶ Perceba que se  $V = 0 \Rightarrow \mu \sim \text{Normal}(M, 0)$ , que é uma distribuição degenerada em  $M$ .
- ▶ Você, *a priori*, está completamente convencido que o valor real de  $\mu$  é  $M$ .
  - ▶ *A posteriori*, tem-se  $E(\mu | x) = M$  e  $\text{Var}(\mu | x) = 0$
  - ▶ A distribuição *a posteriori* de  $\mu$  é  $\mu | \mathbf{x} \sim \text{Normal}(M, 0)$
  - ▶ os dados não modificam o seu conhecimento inicial

**Lei de Cromwell:** Atribua probabilidade zero apenas para eventos que você sabe que não podem nunca ocorrer pois os dados, por mais forte que seja a informação que trazem, não são capazes de modificar/atualizar uma probabilidade nula.

## Dist. Conjugadas: Caso Normal com variância conhecida

IMPORTANTE: Se  $X_1$  e  $X_2$ , dado  $\mu$ , são variáveis aleatórias i.i.d com distribuição  $\text{Normal}(\mu, \sigma^2)$  e se, *a priori*, você estabeleceu que  $\mu \sim \text{Normal}(M, V)$ , podemos dizer que  $X_1$  é independente de  $X_2$ ?

Como  $X_1$  e  $X_2$ , dado  $\mu$ , são variáveis aleatórias independentes temos que  $\text{Cov}(X_1, X_2 \mid \mu) = 0$ .

$$\begin{aligned}\text{Cov}(X_1, X_2) &= E(\text{Cov}(X_1, X_2 \mid \mu)) + \text{COV}(E(X_1 \mid \mu), E(X_2 \mid \mu)) \\ &= E(0) + \text{Cov}(\mu, \mu) = \text{Var}(\mu) = V.\end{aligned}\quad (8)$$

Note que a variância *a priori* para  $\mu$  mensura a correlação entre  $X_1$  e  $X_2$  *a priori*.

## Dist. Conjugadas: Família Exponencial( $\mathcal{FE}$ )

**Definição de Família Exponencial ( $\mathcal{FE}$ ):** Dizemos que uma distribuição de probabilidade  $f(x | \theta)$ ,  $\theta \in \Theta \subseteq \mathbb{R}^k$  e  $x \in \mathcal{X}$ , pertence à **Família Exponencial** se assume a seguinte forma:

$$f(x | \theta) = c(\theta)h(x) \exp\{R(\theta)^t T(x)\}, \quad (9)$$

onde  $c(\cdot)$  e  $h(\cdot)$  são funções não-negativas e  $R(\cdot)$  e  $T(\cdot)$  são funções vetoriais  $k$ -dimensionais.

**Exemplo 1:** Se  $X|\lambda \sim \text{Poisson}(\lambda)$ , temos que

$$f(x | \lambda) = \frac{e^{-\lambda} \lambda^x}{x!} = (x!)^{-1} e^{-\lambda} \exp\{x \ln(\lambda)\}. \quad (10)$$

- ▶ Pertence à família exponencial basta fazer  $h(x) = (x!)^{-1}$ ,  $c(\theta) = e^{-\lambda}$ ,  $T(x) = x$  e  $R(\theta) = \ln(\lambda)$ .
- ▶  $T(x) = x$  é a **Estatística Suficiente** para  $\lambda$ .

## Dist. Conjugadas: Família Exponencial( $\mathcal{FE}$ )

**Exemplo 2:** Se  $X|\theta \sim \text{Uniforme}(a, b)$ , temos que

$$f(x | \lambda) = \frac{1}{b-a} 1\{x \in (a, b)\} = \frac{1}{b-a} \exp\{\ln(1\{x \in (a, b)\})\} \quad (11)$$

- ▶ Não pertence à família exponencial.

**Exemplo 3:** Se  $X|\theta \sim \text{Normal}(\mu, \sigma^2)$ , onde  $\mu$  e  $\sigma^2$  são desconhecidos. Neste caso, temos que

$$\begin{aligned} f(x | \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{\frac{-1}{2\sigma^2}(x^2 - 2x\mu + \mu^2)\right\} \\ &= \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{\frac{-\mu^2}{2\sigma^2}\right\} \exp\left\{\left(\frac{-1}{2\sigma^2}, \frac{\mu}{\sigma^2}\right) \cdot (x^2, 2x)\right\} \end{aligned}$$

- ▶ Pertence à família exponencial. Basta considerar  $h(x) = 1$ ,  $c(\theta) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{\frac{-\mu^2}{2\sigma^2}\right\}$ ,  $T(x) = (x^2, 2x)$  e  $R(\theta) = \left(\frac{-1}{2\sigma^2}, \frac{\mu}{\sigma^2}\right)$ .
- ▶  $T(x) = (x^2, 2x)$  é a **Estatística Suficiente** para  $(\sigma^2, \mu)$ .



## Dist. Conjugadas: Família Exponencial ( $\mathcal{FE}$ )

**Conjugação na Família Exponencial ( $\mathcal{FE}$ ):** Seja

$$\mathcal{F} = \{f(x | \theta) : \theta \in \Theta \subseteq \mathbb{R}^k, x \in \mathcal{X}\},$$

a **Família Exponencial** de distribuições amostrais indexadas pelo parâmetro  $\theta$  tal que

$$f(x | \theta) = c(\theta)h(x) \exp\{R(\theta)^t T(x)\}, \quad (12)$$

onde  $c(\cdot)$  e  $h(\cdot)$  são funções não-negativas e  $R(\cdot)$  e  $T(\cdot)$  são funções vetoriais  $k$ -dimensionais. Então, a família de distribuições de probabilidade definida no espaço paramétrico  $\Theta$ ,  $\mathcal{P} = \{\pi(\theta | a) : a \in \mathcal{A}\}$  tal que

$$\pi(\theta | a) = \frac{c(\theta)^\alpha \exp\{R(\theta)^t \beta\}}{\int_{\Theta} c(\theta)^\alpha \exp\{R(\theta)^t \beta\} d\theta} \quad (13)$$

é conjugada natural da família  $\mathcal{F}$ .

## Distribuições Conjugadas: Família Exponencial

Se  $X_1, \dots, X_n$ , dado  $\theta$ , são condicionalmente independentes e identicamente com distribuição na família exponencial em (12) e, *a priori*,  $\pi(\theta) \in \mathcal{P}$  dada em (13), então a distribuição *a posteriori* é

$$\pi(\theta \mid x_1, \dots, x_n, a) = \frac{c(\theta)^{\alpha+n} \exp\{R(\theta)^t(\beta + T(x_1, \dots, x_n))\}}{\int_{\Theta} c(\theta)^{\alpha+n} \exp\{R(\theta)^t(\beta + T(x_1, \dots, x_n))\} d\theta}$$

A distribuição preditiva *a priori* é

$$f(x_1, \dots, x_n) = \left[ \prod_{i=1}^n h(x_i) \right] \frac{\int_{\Theta} c(\theta)^{\alpha+n} \exp\{R(\theta)^t(\beta + T(x_1, \dots, x_n))\} d\theta}{\int_{\Theta} c(\theta)^{\alpha} \exp\{R(\theta)^t \beta\} d\theta}$$

# Distribuições Conjugadas: Família Exponencial

**Exemplo (Caso Poisson-Gamma):** Se  $X_1, \dots, X_n$ , dado  $\theta$ , são i.i.d com distribuição  $\text{Poisson}(\theta)$ , então a verosimilhança

$$f(\mathbf{x} \mid \theta) = \left[ \prod_{i=1}^n \frac{1}{x_i!} \right] \exp \left\{ \log(\theta) \sum_{i=1}^n x_i \right\} \exp \{-n\theta\}$$

pertence à Família Exponencial em que

$$c(\theta)^n = [\exp \{-\theta\}]^n, \quad h(\mathbf{x}) = \left[ \prod_{i=1}^n \frac{1}{x_i!} \right]$$

$$T(\mathbf{x}) = \sum_{i=1}^n x_i, \quad R(\theta) = \log(\theta)$$

# Distribuições Conjugadas: Família Exponencial

Como consequência do teorema anterior,

- ▶ a família de distribuições de probabilidade definida em  $\Theta$ , que é conjugada natural família amostral Poisson, tem forma

$$\begin{aligned}\pi(\theta) &\propto \exp \{ \log(\theta) \beta \} \exp \{ \alpha \theta \} \\ &\propto \theta^{\beta} \exp \{ -\alpha \theta \},\end{aligned}\tag{14}$$

que é o núcleo de uma distribuição Gama( $\beta - 1, \alpha$ ) com média  $(\beta - 1)/\alpha$ .

- ▶ a distribuição *a posteriori* é

$$\begin{aligned}\pi(\theta | \mathbf{x}) &\propto \exp \left\{ \log(\theta) \left( \beta + \sum_{i=1}^n x_i \right) \right\} \exp \{ (\alpha + n) \theta \} \\ &\propto \theta^{\beta + \sum_{i=1}^n x_i} \exp \{ -(\alpha + n) \theta \},\end{aligned}\tag{15}$$

- ▶  $\Rightarrow A \text{ posteriori, } \theta | \mathbf{x} \sim \text{Gama}(\beta + \sum_{i=1}^n x_i - 1, \alpha + n)$

## Distribuições Conjugadas: Família Exponencial

No caso Poisson-Gama, também se observa que a média *a posteriori* é uma combinação linear convexa do EMV para  $\theta$  e a média *a priori*

$$\begin{aligned} E(\theta | x) &= \frac{\beta + \sum_{i=1}^n x_i - 1}{\alpha + n} \\ &= \frac{\beta - 1}{\alpha + n} + \frac{\sum_{i=1}^n x_i}{\alpha + n} \\ &= \frac{\alpha}{\alpha + n} E(\theta) + \frac{n}{\alpha + n} \bar{X} \end{aligned} \quad (16)$$

Perceba que

- \* Se  $n \rightarrow \infty \Rightarrow E(\theta | x) \rightarrow \bar{X}$ : a informação amostral sobre  $\theta$  é forte e domina a informação *a priori*.
- \* Se  $\alpha \rightarrow 0$  e  $\beta \rightarrow 1 \Rightarrow E(\theta | x) \rightarrow \bar{X}$ : a informação *a priori* é fraca e é dominada pela informação amostral qualquer que seja  $n$ .

## Distribuições Conjugadas: Família Exponencial

**Exemplo (Modelo Linear):** Denote o vector de covariáveis para o  $k$ -ésimo elemento da amostra por  $X_k \in \mathbb{R}^l$  dado por  $(1, X_{k,1}, \dots, X_{k,l-1})$ ,  $k = 1, \dots, n$ , e por  $\beta \in \mathbb{R}^l$  o vetor fixos  $(\beta_0, \dots, \beta_{l-1})^t$ . Assuma que  $(X_k, Y_k)$  segue a estrutura de um modelo linear

$$Y_k = X_k \beta + e_k \quad \text{e} \quad e_k \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \quad (17)$$

Assim, as variáveis  $Y_1, \dots, Y_n$  são independentes e

$$Y_k | X_k, \beta, \sigma^2 \stackrel{\text{ind}}{\sim} \mathcal{N}(X_k \beta, \sigma^2). \quad (18)$$

Na análise conjugada do modelo de regressão assume-se, *a priori* que

$$\beta | \sigma^2 \sim \mathcal{N}_l(m, \sigma^2 V), \quad (19)$$

$$\sigma^2 \sim \mathcal{IG}(\nu/2, d/2), \quad (20)$$

onde  $\nu$  e  $d$  são valores reais positivos,  $m$  é um vetor real  $l \times 1$  e  $V$  é uma matrix  $l \times l$ , positiva definida.

# Distribuições Conjugadas: Família Exponencial

**Exemplo (Modelo Linear, cont.):** Consequentemente, a *posteriori* a inferência é

$$\beta \mid \sigma^2, y, x \sim \mathcal{N}_l(\mathbf{m}^*, \sigma^2 \mathbf{V}^*), \quad (21)$$

$$\sigma^2 \mid \sigma^2, y, x \sim \mathcal{IG}(\nu^*/2, d^*/2), \quad (22)$$

onde

$$\mathbf{m}^* = \mathbf{V}^* (\mathbf{V}^{-1} \mathbf{m} + \mathbf{x}^t \mathbf{x}), \quad (23)$$

$$\mathbf{V}^* = (\mathbf{V}^{-1} + \mathbf{x}^t \mathbf{x})^{-1}, \quad (24)$$

$$\nu^* = \nu + (\mathbf{m})^t \mathbf{V}^{-1} \mathbf{m} + \mathbf{y}^t \mathbf{y} - (\mathbf{m}^*)^t (\mathbf{V}^*)^{-1} \mathbf{m}^*, \quad (25)$$

$$d^* = d + j - i. \quad (26)$$

## Conjugação fora da $\mathcal{FE}$

Se a família de distribuições amostrais  $\mathcal{F}$  é a  $\text{Uniforme}(0, \theta)$ , então a família Pareto de distribuições de probabilidade para  $\theta$  é conjugada natural da família  $\mathcal{F}$ .

**Prova:** Seja  $X_1, \dots, X_n$  uma amostra que, dado,  $\theta$  é i.i.d. tal que  $X_i | \theta \stackrel{iid}{\sim} \text{Uniforme}(0, \theta)$ . Então a função de verossimilhança é

$$\begin{aligned} f(\mathbf{x} | \theta) &= \prod_{i=1}^n \frac{1}{\theta} 1(x_i \in (0, \theta)) \\ &= (\theta)^{-n} 1(\max\{x_1, \dots, x_n\} < \theta) \end{aligned}$$

**Construindo uma família fechada por amostragem com respeito a  $\mathcal{F}$ :** Para que isto ocorra a família de distribuições  $\mathcal{P}$  sobre  $\theta$  tem que ter núcleo proporcional ao núcleo da verossimilhança, isto é,

$$\pi(\theta) \propto \text{Kernell}(f(\mathbf{x} | \theta)) = \left(\frac{1}{\theta}\right)^{??} 1(\theta > ??)$$



## Conjugação fora da $\mathcal{FE}$

Incluindo parâmetros pra torná-la flexível: A família  $\mathcal{P}$  sobre  $\theta$  candidata a família conjugada natural de  $\mathcal{F}$  tem a seguinte fdp

$$\pi(\theta) = \beta \alpha^\beta (\theta)^{-(\beta+1)} \mathbf{1}(\theta > \alpha),$$

ou seja,  $\theta \sim \text{Pareto}(\alpha, \beta)$ .

**Provando o fechamento por produto:** Tomemos a distribuição *a priori* para  $\theta$  pertencente à família Parto, i.é,  $\theta \sim \text{Pareto}(\alpha, \beta)$ . Daí, a distribuição *a posteriori* é

$$\begin{aligned} \pi(\theta \mid \mathbf{x}) &= \frac{(\theta)^{-n} \mathbf{1}(\max\{x_1, \dots, x_n\} < \theta) * \beta \alpha^\beta (\theta)^{-(\beta+1)} \mathbf{1}(\theta > \alpha)}{\int (\theta)^{-n} \mathbf{1}(\max\{x_1, \dots, x_n\} < \theta) * \beta \alpha^\beta (\theta)^{-(\beta+1)} \mathbf{1}(\theta > \alpha) d\theta} \\ &= \frac{\theta^{-(n+\beta+1)} \mathbf{1}(\theta > \max[\max\{x_1, \dots, x_n\}, \alpha])}{\int_{\theta > \max[\max\{x_1, \dots, x_n\}, \alpha]} \theta^{-(n+\beta+1)} d\theta} \end{aligned}$$

## Conjugação fora da $\mathcal{FE}$

Note que, no denominador, estamos integrando o núcleo de uma distribuição  $Pareto(\alpha^*, \beta + n)$  onde  $\alpha^* = \max[\max\{x_1, \dots, x_n\}, \alpha]$ .

A integral do denominador é  $[(\alpha^*)^{\beta+n}(\beta + n)]^{-1}$ .

A distribuição *a posteriori* para  $\theta$  é

$$\theta \sim Pareto(\alpha^*, \beta + n)$$

onde  $\alpha^* = \max[\max\{x_1, \dots, x_n\}, \alpha]$ .

Como a família  $\mathcal{P}$  é fechada sob a amostragem de  $\mathcal{F}$  e  $\mathcal{P}$  é fechada por produto, provamos que as famílias  $Uniforme(0, \theta)$  e  $Pareto(\alpha, \beta)$  são conjugadas naturais.

# Conjugação na família de mistura finita de distribuições

Seja  $\mathcal{F}$  uma família de distribuições amostrais indexadas pelo parâmetro  $\theta$ , isto é,

$$\mathcal{F} = \{f(\mathbf{x} \mid \theta) : \theta \in \Theta, \mathbf{x} \in \mathcal{X}\}.$$

Se a distribuição *a priori* para  $\theta$  é uma mistura finita de distribuições, ou seja, se  $\pi(\theta) = \sum_{i=1}^k \omega_i \pi_i(\theta)$ ,  $\omega_i \in (0, 1)$ ,  $\sum_{i=1}^k \omega_i = 1$ , e  $\pi_i(\theta)$  é uma função densidade ou função de probabilidade, então

- ▶ a distribuição preditiva *a priori*  $f(\mathbf{x})$  é também uma mistura finita de distribuições dada por

$$f(\mathbf{x}) = \sum_{i=1}^k \omega_i f_i(\mathbf{x}),$$

$f_i(\mathbf{x}) = \int_{\Theta} f(\mathbf{x} \mid \theta) \pi_i(\theta) d\theta$  é a distribuição preditiva *a priori* com respeito ao componente  $\pi_i(\theta)$  da mistura.

# Conjugação na família de mistura finita de distribuições

**Prova:** Da definição de distribuição preditiva *a priori* segue que

$$\begin{aligned}f(\mathbf{x}) &= \int_{\Theta} f(\mathbf{x} \mid \theta) \pi(\theta) d\theta \\&= \int_{\Theta} f(\mathbf{x} \mid \theta) \sum_{i=1}^k \omega_i \pi_i(\theta) d\theta \\&= \sum_{i=1}^k \omega_i \int_{\Theta} f(\mathbf{x} \mid \theta) \pi_i(\theta) d\theta \\&= \sum_{i=1}^k \omega_i f_i(\mathbf{x})\end{aligned}\tag{27}$$

# Conjugação na família de mistura finita de distribuições

- a distribuição *a posteriori* é uma mistura finita tal que

$$\pi(\theta | x) = \sum_{i=1}^k \omega_i^* \pi_i(\theta | x)$$

onde  $\omega_i^* = \frac{\omega_i f_i(x)}{\sum_{i=1}^k \omega_i f_i(x)}$  e  $f_i(x) = \int_{\Theta} f(x | \theta) \pi_i(\theta) d\theta$  é a distribuição preditiva *a priori* com respeito ao componente  $\pi_i(\theta)$  da mistura.

# Conjugação na família de mistura finita de distribuições

**Prova:** usando o teorema de Bayes temos que

$$\begin{aligned}\pi(\theta | \mathbf{x}) &= \frac{f(\mathbf{x} | \theta)\pi(\theta)}{\int_{\Theta} f(\mathbf{x} | \theta)\pi(\theta)d\theta} \\&= \frac{f(\mathbf{x} | \theta) \sum_{i=1}^k \omega_i \pi_i(\theta)}{\int_{\Theta} f(\mathbf{x} | \theta) \sum_{i=1}^k \omega_i \pi_i(\theta)d\theta} \\&= \frac{\sum_{i=1}^k \omega_i f(\mathbf{x} | \theta) \pi_i(\theta)}{\sum_{i=1}^k \omega_i f_i(\mathbf{x})} \\&= \sum_{i=1}^k \frac{\omega_i}{\sum_{i=1}^k \omega_i f_i(\mathbf{x})} f(\mathbf{x} | \theta) \pi_i(\theta) \\&= \sum_{i=1}^k \frac{\omega_i \int_{\Theta} f(\mathbf{x} | \theta) \pi_i(\theta)d\theta}{\sum_{i=1}^k \omega_i f_i(\mathbf{x})} \frac{f(\mathbf{x} | \theta) \pi_i(\theta)}{\int_{\Theta} f(\mathbf{x} | \theta) \pi_i(\theta)d\theta} \\&= \sum_{i=1}^k \frac{\omega_i f_i(\mathbf{x})}{\sum_{i=1}^k \omega_i f_i(\mathbf{x})} \pi_i(\theta | \mathbf{x})\end{aligned}$$

# Conjugação na família de mistura finita de distribuições

**Exemplo:** Se  $X_1, \dots, X_n$ , dado  $\theta$ , são i.i.d com distribuição Poisson( $\theta$ ). Assuma que a distribuição *a priori* para  $\theta$  é a seguinte mistura finita de distribuições gama:

$$\pi(\theta) = pF_{G_1}(\alpha_1, \beta_1) + (1 - p)F_{G_2}(\alpha_2, \beta_2),$$

onde  $F_{G_i}(\alpha_i, \beta_i)$  representa a densidade de uma distribuição Gama( $\alpha_i, \beta_i$ ),  $p \in (0, 1)$ ,  $\alpha_i > 0$  e  $\beta_i > 0$ ,  $i = 1, 2$ . Encontre (a) a distribuição preditiva *a priori* e (b) a distribuição *a posteriori* de  $\theta$ .

**Solução:** Considerando o resultado anterior precisamos encontrar as distribuições *a posteriori* e preditiva *a priori* para cada componente da mistura.

# Conjugação na família de mistura finita de distribuições

## a) Dist. preditiva *a priori* :

Dist. preditiva *a priori* para o componente  $j$ :

$$\begin{aligned}f_j(\mathbf{x}) &= \int_0^\infty \left(\prod_{i=1}^n 1/x_i!\right) \exp\{-n\theta\} \theta^{\sum_{i=1}^n x_i} \frac{\beta_j^{\alpha_j}}{\Gamma(\alpha_j)} \theta^{\alpha_j-1} \exp\{-\beta_j\theta\} d\theta \\&= \left(\prod_{i=1}^n 1/x_i!\right) \frac{\beta_j^{\alpha_j}}{\Gamma(\alpha_j)} \int_0^\infty \theta^{\sum_{i=1}^n x_i + \alpha_j - 1} \exp\{-(\beta_j + n)\theta\} d\theta \\&= \left(\prod_{i=1}^n 1/x_i!\right) \frac{\beta_j^{\alpha_j}}{\Gamma(\alpha_j)} \frac{\Gamma(\sum_{i=1}^n x_i + \alpha_j)}{(\beta_j + n)^{\sum_{i=1}^n x_i + \alpha_j}}, \quad x_i = 0, 1, \dots, i = 1, \dots, n.\end{aligned}$$

Dist. preditiva *a priori*

$$f(\mathbf{x}) = \left(\prod_{i=1}^n 1/x_i!\right) \left\{ p \frac{\beta_1^{\alpha_1}}{\Gamma(\alpha_1)} \frac{\Gamma(\sum_{i=1}^n x_i + \alpha_1)}{(\beta_1 + n)^{\sum_{i=1}^n x_i + \alpha_1}} + (1-p) \frac{\beta_2^{\alpha_2}}{\Gamma(\alpha_2)} \frac{\Gamma(\sum_{i=1}^n x_i + \alpha_2)}{(\beta_2 + n)^{\sum_{i=1}^n x_i + \alpha_2}} \right\}$$

para todo  $x_i = 0, 1, \dots, i = 1, \dots, n$ .



# Conjugação na família de mistura finita de distribuições

## b) Dist. *a posteriori* :

Distribuição *a posteriori* para cada componente da mistura: Como as distribuições Gama e Poisson são conjugadas naturais temos que para cada componente da mistura

$$\pi_j(\theta|\mathbf{x}) \propto \theta^{\sum_{i=1}^n x_i + \alpha_j - 1} \exp\{-(\beta_j + n)\theta\}.$$

Assim, *a posteriori*, cada componente  $j$  da mistura é uma *Gama*( $\sum_{i=1}^n x_i + \alpha_j, \beta_j + n$ )

A distribuição *a posteriori* para  $\theta$  é uma mistura finita das distribuições *Gama*( $\sum_{i=1}^n x_i + \alpha_1, \beta_1 + n$ ) e *Gama*( $\sum_{i=1}^n x_i + \alpha_2, \beta_2 + n$ ) onde o peso da primeira componente da mistura é

$$p^* = \frac{p \frac{\beta_1^{\alpha_1}}{\Gamma(\alpha_1)} \frac{\Gamma(\sum_{i=1}^n x_i + \alpha_1)}{(\beta_1 + n)^{\sum_{i=1}^n x_i + \alpha_1}}}{\left\{ p \frac{\beta_1^{\alpha_1}}{\Gamma(\alpha_1)} \frac{\Gamma(\sum_{i=1}^n x_i + \alpha_1)}{(\beta_1 + n)^{\sum_{i=1}^n x_i + \alpha_1}} + (1 - p) \frac{\beta_2^{\alpha_2}}{\Gamma(\alpha_2)} \frac{\Gamma(\sum_{i=1}^n x_i + \alpha_2)}{(\beta_2 + n)^{\sum_{i=1}^n x_i + \alpha_2}} \right\}}$$