

Inferência Estatística com Abordagem Bayesiana

Rosangela Helena Loschi ¹

¹Departamento de Estatística
Universidade Federal de Minas Gerais

19 de janeiro de 2021

MÉTODOS DE CONSTRUÇÃO DA DISTRIBUIÇÃO *A PRIORI*

- ▶ Distribuições conjugadas naturais
- ▶ **Distribuições de referências: Métodos Bayes-laplace e Jeffreys**

Distribuições referência ou não-informativas

Muitas vezes as distribuições conjugadas

- ▶ podem não representar bem o conhecimento inicial do indivíduo sobre o parâmetro ou
- ▶ podem não existir.

Outra forma muito comumente utilizada para fazer uma análise Bayesiana é o uso de **distribuições *a priori* não-informativas ou de referência**. Algumas justificativas para usá-las

- (1) desconhecimento sobre o problema
- (2) ter informação mas não querer utilizá-la
- (3) querer **ser objetivo**.

Existem muitas classes de distribuições *a priori* não-informativas pois não há um consenso sobre o que é não-informação.

Dist. não-informativas: Sentido Bayes-Laplace

- ▶ Estão baseadas no **Princípio da Razão Insuficiente**: “se não há informação para diferenciar entre os valores de $\theta \in \Theta$ devemos atribuir a todos estes valores a mesma probabilidade”.
- ▶ Sob este princípio: a **distribuição a priori de qualquer parâmetro é uma distribuição Uniforme no espaço paramétrico Θ** .

Exemplo:

- ▶ Se $\Theta = \{\theta_1, \dots, \theta_N\} \Rightarrow \pi(\theta_i) = P(\theta = \theta_i) = 1/N$
- ▶ Se $\Theta = [a, b] \subset \mathbb{R} \Rightarrow \pi(\theta) = (b - a)^{-1}$
- ▶ Se $\Theta = \{\theta_1, \theta_2, \dots\} \Rightarrow \pi(\theta_i) = P(\theta = \theta_i) \propto K$, constante.
(Note que $\sum_{i=1}^{\infty} \pi(\theta) = \sum_{i=1}^{\infty} K = \infty$ (imprópria))
- ▶ Se $\Theta = \mathbb{R} \Rightarrow \pi(\theta) \propto K$, constante.

Dist. não-informativas: Sentido Bayes-Laplace

Criticas a este procedimento:

(1) sob este princípio **não há invariância**

- ▶ Se o espaço paramétrico é $\Theta = (0, 1)$, usando este princípio, *a priori*, $\theta \sim \text{Uniforme}(0, 1)$.
- ▶ Se a meta é especificar a distribuição *a priori* para a reparametrização $\phi = -\log(\theta)$ do modelo
 - * Se usássemos o Princípio da Razão Insuficiente, a distribuição *a priori* para ϕ que é não-informativa no sentido de Bayes-Laplace deveria ser uma uniforme no intervalo $(0, \infty)$.
 - * No entanto, como $\theta \sim \text{Uniforme}(0, 1)$, usando técnicas de prob., provamos que $\phi = g(\theta) = -\log(\theta) \sim \text{Exponencial}(1)$ ← **nao seguimos o Princípio da Razão Insuficiente na especificação da distribuição de ϕ .**

$$g^{-1}(\phi) = e^{-\phi}$$

$$\pi(\phi) = \pi(g^{-1}(\phi)) \left| \frac{dg^{-1}(\phi)}{d\theta} \right| = 1 * |-e^{-\phi}|,$$

$$\text{se } g^{-1}(\phi) \in (0, 1) \Rightarrow e^{-\phi} \in (0, 1) \Rightarrow \phi \in (0, \infty).$$

Dist. não-informativas: Sentido Bayes-Laplace

(2) podemos construir distribuições *a priori* **impróprias** \leftarrow não são medidas de probabilidade.

- ▶ Estamos violando o **Princípio da Coerência**
- ▶ Não é visto como um problema sério se a distribuição *a posteriori* é própria.
- ▶ Neste caso,
 - ▶ teríamos inferência *a posteriori* mas não teríamos inferência *a priori*.
 - ▶ usaremos uma regra geral de condicionamento para construirmos a distribuição *a posteriori*

Exemplo: SeJa X_1, \dots, X_n , dado μ , são variáveis aleatórias i.i.d com distribuição Normal(μ, σ^2), em que a variância σ^2 é conhecida. Para o parâmetro μ , temos que

- * o espaço paramétrico é \mathbb{R} .
- * a distribuição *a priori* não-informativa no sentido de Bayes-Laplace é $\pi(\mu) \propto 1, \forall \mu \in \mathbb{R} \leftarrow$ é imprópria.

Dist. não-informativas: Sentido Bayes-Laplace

- a função de verossimilhança é

$$\begin{aligned}f(\mathbf{x} \mid \mu) &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp \left\{ \frac{-1}{2\sigma^2} (x_i - \mu)^2 \right\} \\&= (2\pi\sigma^2)^{-n/2} \exp \left\{ \frac{-1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right) \right\} \\&= (2\pi\sigma^2)^{-n/2} \exp \left\{ \frac{-1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right\} \\&\times \exp \left\{ \frac{-1}{2\sigma^2} \left(-2\mu \sum_{i=1}^n x_i + n\mu^2 \right) \right\} \\&\propto \exp \left\{ -\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x}) \right\}\end{aligned}$$

- Segue que o núcleo da distribuição *a posteriori* para μ é

$$\pi(\mu \mid \mathbf{x}) \propto \exp \left\{ -\frac{n}{2\sigma^2} (\mu^2 - 2\mu\bar{x}) \right\}.$$

Dist. não-informativas: Sentido Bayes-Laplace

- ▶ Assim, a distribuição *a posteriori* para μ é

$$\mu \mid x \sim \text{Normal}(\bar{x}, \sigma^2/n)$$

a qual é uma distribuição própria.

- ▶ Neste caso, **não há inferência *a priori* mas sempre há inferência *a posteriori*.**

Atenção:

- ▶ Quando utilizamos uma distribuição *a priori* **própria**, a distribuição *a posteriori* é **sempre própria**.
- ▶ Se consideramos uma distribuição *a priori* **imprópria**, não temos garantia de que a distribuição *a posteriori* será própria. Neste caso,
 - ▶ **devemos provar que a distribuição *a posteriori* é própria antes iniciarmos nossa análise.**

Dist. não-informativas: problema com dist. impróprias

Exemplo: Suponha que $X_i \mid \theta \stackrel{iid}{\sim} \text{Binomial}(1, \theta)$ e que a distribuição *a priori* para θ seja

$$\pi(\theta) \propto \theta^{-1}(1 - \theta)^{-1} \leftarrow \text{Beta}(0, 0)(\text{imprópria})$$

Se observamos $\sum_{i=1}^n x_i = n$ temos que a distribuição *a posteriori* para θ é

$$\pi(\theta \mid \mathbf{x}) \propto \theta^{-1}(1 - \theta)^{-1} \theta^n (1 - \theta)^0 \propto \theta^{n-1}(1 - \theta)^{-1}$$

Isto implica que a distribuição *a posteriori* para θ é uma distribuição $\text{Beta}(n, 0)$ que também é imprópria. Não há inferência *a posteriori*.

A condição para termos uma distribuição *a posteriori* própria é termos pelo menos um zero na amostra.

Dist. não-informativas *versus* distribuições conjugadas

No caso em que X_1, \dots, X_n , dado μ , são variáveis aleatórias i.i.d com distribuição $\text{Normal}(\mu, \sigma^2)$, em que a variância σ^2 é conhecida, obtemos que

- ▶ A distribuição *a priori* conjugada da família normal com variância conhecida é $\mu \sim \text{Normal}(M, V)$ cujo núcleo é

$$\pi_C(\mu) \propto \exp \left\{ -\frac{1}{2V}(\mu - M)^2 \right\}$$

- ▶ Se assumirmos que $V \rightarrow \infty$ tínhamos uma distribuição vaga, que era dominada pelos dados quaisquer que fosse n .
- ▶ Note que

$$\lim_{V \rightarrow \infty} \exp \left\{ -\frac{1}{2V}(\mu - M)^2 \right\} = 1$$

- ▶ Isto implica que se $V \rightarrow \infty$ o grau de informação trazido pela distribuição *a priori* conjugada $\pi_C(\mu)$ se aproxima daquele fornecido pela distribuições de Jeffreys (ver a seguir) e Bayes-Laplace.

Dist. não-informativas: Sentido Jeffreys

A distribuição *a priori* de Jeffreys é definida considerando-se a **Informação de Fisher** sobre θ .

A Informação de Fisher sobre θ denotada por $I(\theta)$

- (1) mede a curvatura média da função de verossimilhança
- (2) maior a curvatura da verossimilhança
 - ▶ \Rightarrow maior informação sumarizada pela verossimilhança (ou por \mathbf{X}) sobre θ
 - ▶ \Rightarrow maior é o valor da Informação de Fisher $I(\theta)$ no ponto θ .

Dist. não-informativas: Sentido Jeffreys

Definição(Informação de Fisher): Se \mathbf{X} é um vetor/variável aleatória com função densidade (ou de probabilidade) $f(\mathbf{X} | \theta)$,

- ▶ se $\theta \in \Theta \subset \mathbb{R}$, a **Informação de Fisher** esperada é um número $I(\theta)$ dado por

$$I(\theta) = E_{\mathbf{X}|\theta} \left[-\frac{d^2}{d\theta^2} \ln f(\mathbf{X} | \theta) \right]$$

- ▶ se $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$, a **Informação de Fisher** esperada é uma matriz $I(\boldsymbol{\theta})$ dado por

$$I(\boldsymbol{\theta}) = E_{\mathbf{X}|\boldsymbol{\theta}} \left[-\frac{\partial^2}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^T} \ln f(\mathbf{X} | \boldsymbol{\theta}) \right]$$

onde cada entrada ij da matriz $I(\boldsymbol{\theta})$ é dada por:

$$I_{ij}(\boldsymbol{\theta}) = E_{\mathbf{X}|\boldsymbol{\theta}} \left[-\frac{\partial^2}{\partial \theta_i \partial \theta_j} \ln f(\mathbf{X} | \boldsymbol{\theta}) \right]$$

Dist. não-informativas: Sentido Jeffreys

Definição: A *distribuição a priori* de Jeffreys é assim definida

► se $\theta \in \Theta \subset \mathbb{R}$,

$$\pi(\theta) \propto [I(\theta)]^{1/2}, \forall \theta \in \Theta.$$

► se $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$,

$$\pi(\boldsymbol{\theta}) \propto [\det I(\boldsymbol{\theta})]^{1/2}, \forall \boldsymbol{\theta} \in \Theta.$$

Dist. de Jeffreys: Modelo Bernoulli

Seja X_1, \dots, X_n , dado θ , são i.i.d com distribuição Bernoulli(θ).

- * Como $\Theta = (0, 1)$ a distribuição de Bayes-Laplace é a distribuição Uniforme(0, 1) que pertence a família Beta.
- * Cálculo da informação de Fisher para o modelo Bernoulli

$$\ln f(\mathbf{x} \mid \theta) = \sum_{i=1}^n x_i \ln \theta + (n - \sum_{i=1}^n x_i) \ln(1 - \theta)$$

$$\frac{d}{d\theta} \ln f(\mathbf{x} \mid \theta) = \frac{\sum_{i=1}^n x_i}{\theta} - \frac{(n - \sum_{i=1}^n x_i)}{(1 - \theta)}$$


$$\frac{d^2}{d\theta^2} \ln f(\mathbf{x} \mid \theta) = -\frac{\sum_{i=1}^n x_i}{\theta^2} - \frac{(n - \sum_{i=1}^n x_i)}{(1 - \theta)^2}$$

Dist. de Jeffreys: Modelo Bernoulli

A informação de Fisher para o modelo Bernoulli é

$$I(\theta) \propto \theta^{-1}(1 - \theta)^{-1}.$$

Informação de Fisher: caso bernoulli, n=2



Dist. de Jeffreys: Modelo Bernoulli

- * Consequentemente, a distribuição de Jeffreys é

$$\pi(\theta) \propto \theta^{-1/2}(1 - \theta)^{-1/2} \Rightarrow \theta \sim \text{Beta}(1/2, 1/2).$$

- * As distribuições de Jeffreys e Bayes-Laplace são próprias e ambas pertencem a família Beta.

Observação Importante sobre a Informação de Fisher:

- ▶ Se $\mathbf{X} = (X_1, \dots, X_n)$ são variáveis aleatórias independentes com $X_i | \theta \sim f_i(x_i | \theta)$, se $I_i(\theta)$ denota a Informação de Fisher calculada com base apenas na distribuição de X_i e $I(\theta)$ é a informação de Fisher calculada com base na amostra \mathbf{X} então

$$I(\theta) = \sum_{i=1}^n I_i(\theta);$$

- ▶ Se $\mathbf{X} = (X_1, \dots, X_n)$ são variáveis aleatórias independentes e identicamente distribuídas se $I(\theta)$ denota a Informação de Fisher calculada com base apenas na distribuição de cada X_i e $I_n(\theta)$ é a informação de Fisher calculada com base na amostra \mathbf{X} então

$$I_n(\theta) = nI(\theta)$$

Dist. não-informativas: Sentido Jeffreys

Exemplo: Se X_1, \dots, X_n , dado λ , são variáveis aleatórias i.i.d com distribuição exponencial com parametro λ cuja f.d.p. é

$$f(x_i | \lambda) = \lambda \exp\{-\lambda x_i\}, \quad x_i > 0. \quad (1)$$

(a) Encontre a distribuição *a priori* de Jeffreys para λ e (b) determine se a distribuição *a posteriori* é própria.

Solução: (a) Como a amostra é i.i.d. basta encontrarmos a informação de Fisher para X_i . Tomando o log da função de verossimilhança para X_i dada em (7) temos

$$\ln f(x_i | \lambda) = \ln \lambda - \lambda x_i$$

Derivando com respeito a λ temos

$$\frac{d}{d\lambda} \ln f(x_i | \lambda) = 1/\lambda - x_i$$

$$\frac{d^2}{d^2\lambda} \ln f(x_i | \lambda) = -1/\lambda^2.$$

Dist. não-informativas: Sentido Jeffreys


Dai, a Informação de Fisher sobre λ é

$$I(\lambda) = E_{X_i|\lambda} \left(-\frac{d^2}{d^2\lambda} \ln f(x_i | \lambda) \right) = E_{X_i|\lambda}(\lambda^{-2}) = \lambda^{-2}$$

Por definição, a distribuição *a priori* de Jeffreys para λ é

$$\pi(\lambda) \propto I(\lambda)^{1/2} = (\lambda^{-2})^{1/2} = 1/\lambda, \quad \lambda > 0. \quad (2)$$

$\Rightarrow \lambda \sim \text{Gama}(0,0) \leftarrow$ É imprópria!



Dist. não-informativas: Sentido Jeffreys

Exemplo (cont): (b) A função de verossimilhança é

$$\begin{aligned} f(\mathbf{x} \mid \lambda) &= \prod_{i=1}^n \lambda \exp\{-\lambda x_i\} \\ &= \lambda^n \exp\{-\lambda \sum_{i=1}^n x_i\} \end{aligned} \quad (3)$$

Considerando a distribuição *a priori* encontrada no item (a), temos que a distribuição *a posteriori* para λ é:

$$\begin{aligned} \pi(\lambda \mid \mathbf{x}) &\propto \lambda^n \exp\{-\lambda \sum_{i=1}^n x_i\} * 1/\lambda \\ &\propto \lambda^{n-1} \exp\{-\lambda \sum_{i=1}^n x_i\} \end{aligned} \quad (4)$$

Note de (4) que a distribuição *a posteriori* para λ é uma distribuição *Gama*($n, \sum_{i=1}^n x_i$). É própria se $n > 0$ e $\sum_{i=1}^n x_i > 0$.

Dist. não-informativas: Sentido Jeffreys

Observação: Considere o log da função de verossimilhança em (3)

$$\ln f(\mathbf{x} \mid \lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i \quad (5)$$

Derivando com respeito a λ temos

$$\frac{d}{d\lambda} \ln f(x_i \mid \lambda) = n/\lambda - \sum_{i=1}^n x_i$$

$$\frac{d^2}{d^2\lambda} \ln f(x_i \mid \lambda) = -n/\lambda^2.$$

Ou seja, como a amostra é iid, temos que

$$I_n(\lambda) = n(1/\lambda^2) = nI(\lambda),$$

como afirmado na teoria.

Dist. não-informativas: Sentido Jeffreys

A distribuição *a priori* de Jeffreys

- * atribui mais peso aos valores de θ que são mais diferenciados pelo modelo estatístico.
- * "Não é subjetiva" desde que não resume a informação inicial sobre θ .
- * A única subjetividade envolvida em sua construção vem da subjetividade inerente à construção do modelo.
- * Viola alguns princípios Bayesianos ([Princípio da Verosimilhança](#)) pois considera o princípio da repetibilidade amostral.
- * Também pode ser imprópria.
- * Qual é o ganho deste método se comparado ao método de Bayes-Laplace?

Dist. não-informativas: Sentido Jeffreys

* É invariante sob transformações um-a-um.

Proposição: Se a distribuição *a priori* de θ é não informativa no sentido de Jeffreys e se $\phi = g(\theta)$, onde g é uma transformação bijetiva de θ , então, *a priori*

$$\pi(\phi) \propto [I(\phi)]^{1/2}.$$

A prova segue utilizando-se o método do jacobiano e a seguinte propriedade da informação de Fisher

$$I(\phi) = I(\theta) \left(\frac{d\theta}{d\phi} \right)^2.$$

Dist. não-informativas: Sentido Jeffreys

Exemplo (cont.): Se X_1, \dots, X_n , dado λ , são variáveis aleatórias i.i.d com distribuição exponencial com parametro λ cuja f.d.p. é

$$f(x_i | \lambda) = \lambda \exp\{-\lambda x_i\}, \quad x_i > 0. \quad (6)$$

Considere a seguinte reparametrização do modelo $\theta = 1/\lambda$ e encontre a distribuição *a priori* de Jeffreys para θ .

Solução 1-Reparametrizando a fdp: Sob a re-parametrização dada temos que a fdp torna-se

$$f(x_i | \theta) = 1/\theta \exp\{-x_i/\theta\}, \quad x_i > 0.$$

$$\begin{aligned} \text{Daí, } \ln f(x_i | \theta) &= -\ln \theta - x_i/\theta \Rightarrow \frac{d}{d\theta} \ln f(x_i | \theta) = -1/\theta + x_i/\theta^2 \\ \Rightarrow \frac{d^2}{d\theta^2} \ln f(x_i | \theta) &= 1/\theta^2 - 2x_i/\theta^3. \end{aligned}$$

Com isto, temos que a Informação de Fisher sobre θ é

$$I(\theta) = -1/\theta^2 + 2E(X_i)/\theta^3 = -1/\theta^2 + 2\theta/\theta^3 = 1/\theta^2$$

Portanto, distribuição *a priori* de Jeffreys para θ é

$$\pi(\theta) \propto \theta^{-1}, \quad \theta > 0.$$

Dist. não-informativas: Sentido Jeffreys

Solução 2- usando a propriedade da Informação de Fisher:

A Informação de Fisher para λ é

$$I(\lambda) = 1/\lambda^2, \quad \lambda > 0.$$

Usando a propriedade da Informação de Fisher temos que

$$I(\theta) = I(\lambda) \left(\frac{d\lambda}{d\theta} \right)^2.$$

Agora $\theta = 1/\lambda \Rightarrow \lambda = 1/\theta$.

Substituindo na expressão anterior temos

$$I(\theta) = \left(\frac{1}{1/\theta} \right)^2 \left(\frac{d}{d\theta}(1/\theta) \right)^2 = (\theta)^2 (-1/\theta^2)^2 = 1/\theta^2$$

Chegamos ao mesmo resultado mostrado na Solução 1 para a Informação de Fisher.

Dist. não-informativas: Sentido Jeffreys

Solução 3-Partindo da distribuição de Jeffreys para λ : Da equação (2) obtemos que a distribuição *a priori* de Jeffreys para λ é

$$\pi_L(\lambda) \propto 1/\lambda, \quad \lambda > 0.$$

Assim, utilizando resultados de cálculo de probabilidade para encontramos a distribuição de θ temos que $\forall \theta : \theta = g(\lambda)$ para algum $\lambda > 0$, então $\pi_T(\theta) \propto \pi_L(g^{-1}(\theta)) \left| \frac{d}{d\theta} g^{-1}(\theta) \right|$. Daí, temos que

$$\theta = 1/\lambda = g(\lambda) \Rightarrow \lambda = g^{-1}(\theta) = 1/\theta \Rightarrow \frac{d}{d\theta} g^{-1}(\theta) = -1/\theta^2$$

$$\pi_T(\theta) \propto \pi_L(1/\theta) \left| -1/\theta^2 \right| = \theta/\theta^2$$

Portanto, distribuição *a priori* de Jeffreys para θ é

$$\pi(\theta) \propto \theta^{-1}, \quad \theta > 0.$$

\Rightarrow o princípio de "não" informação é preservado!

Dist. não-informativas: Sentido Jeffreys

Alguns casos particulares de distribuição *a priori* de Jeffreys.

- * **Família exponencial uni-paramétrica:** Se $f(x | \theta) = h(x) \exp\{\theta T(x) - \psi(\theta)\}$ $\theta \in \mathbb{R}$, então a distribuição *a priori* de Jeffreys é

$$\pi(\theta) \propto \left[\frac{d^2 \psi(\theta)}{d\theta^2} \right]^{1/2} = [\psi''(\theta)]^{1/2}$$

Note que $\ln f(x | \theta) = \ln h(x) + \theta T(x) - \psi(\theta)$. Daí

$$\begin{aligned} \frac{d}{d\theta} \ln f(x | \theta) &= T(x) - \psi'(\theta) \\ \frac{d^2}{d\theta^2} \ln f(x | \theta) &= -\psi''(\theta) \end{aligned}$$

$$\Rightarrow I(\theta) = -E_{X|\theta}(-\psi''(\theta)) = -\psi''(\theta) \Rightarrow \pi(\theta) \propto [\psi''(\theta)]^{1/2}$$

Dist. não-informativas: Sentido Jeffreys

Exemplo: Se X , dado λ , tem distribuição exponencial com parâmetro λ então

$$f(x | \lambda) = \lambda \exp\{-\lambda x\} = \exp\{-\lambda x + \ln \lambda\} \quad (7)$$

Neste caso, $\psi(\lambda) = -\ln \lambda \Rightarrow \psi'(\lambda) = -1/\lambda \Rightarrow \psi''(\lambda) = 1/\lambda^2$.
Usando o resultado anterior segue que a distribuição *a priori* de Jeffreys para λ é

$$\pi(\lambda) \propto \lambda^{-1}, \quad \lambda > 0.$$

Dist. não-informativas: Sentido Jeffreys

- * **Família Localização:** Se $f(x | \theta) = f(x - \theta)$ e, portanto, θ é um parâmetro de localização então $\pi(\theta) \propto 1$.

Exemplo: Suponha que $X | \mu \sim N(\mu, \sigma^2)$, com σ^2 conhecido. Então, a função de verossimilhança é

$$f(x|\mu) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left\{ \frac{-1}{2\sigma^2} (X - \mu)^2 \right\} \leftarrow f(x - \mu)$$

O logaritmo da função de verossimilhança é

$$\ln f(x|\mu) = \frac{1}{2} \ln \left(\frac{1}{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (X - \mu)^2$$

Daí

$$\frac{d}{d\mu} f(x|\mu) = \frac{(X - \mu)}{\sigma^2} \Rightarrow \frac{d^2}{d\mu^2} f(x|\mu) = -\frac{1}{\sigma^2}$$

Dist. não-informativas: Sentido Jeffreys

A informação de Fisher com respeito a μ é

$$I(\mu) = -E_{X|\mu} \left(-\frac{1}{\sigma^2} \right) = \frac{1}{\sigma^2} \leftarrow \text{constante}$$

Por definição, a distribuição *a priori* de Jeffreys para μ é

$$\pi(\mu) \propto \left[\frac{1}{\sigma^2} \right]^{1/2} \propto 1$$

- ▶ É imprópria e coincide com a distribuição não-informativa no sentido de Bayes-Laplace.
- ▶ Como vimos, a distribuição *a posteriori* para μ é

$$\mu \mid x \sim \text{Normal}(\bar{x}, \sigma^2/n)$$

a qual é uma distribuição própria.

Dist. não-informativas: Sentido Jeffreys

* **Família Escala** : Se $f(x | \theta) = \frac{1}{\theta} f(\frac{x}{\theta})$ e, portanto, θ é um parâmetro de escala então $\pi(\theta) \propto 1/\theta$.

Exemplo: Suponha que $X | \sigma^2 \sim N(\mu, \sigma^2)$, com μ conhecido. Então, a função de verossimilhança é

$$f(x|\sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left\{ \frac{-1}{2\sigma^2} (X - \mu)^2 \right\} \leftarrow 1/\sigma^2 f(x/\sigma^2)$$

O logaritmo da função de verossimilhança é

$$\ln f(x|\sigma^2) = -\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} (X - \mu)^2$$

Daí, a primeira e segunda derivadas com respeito a σ^2 são:

$$\frac{d}{d\sigma^2} f(x|\sigma^2) = \frac{-1}{2\sigma^2} + \frac{(X - \mu)^2}{2(\sigma^2)^2}$$

e

$$\frac{d^2}{d(\sigma^2)^2} f(x|\sigma^2) = \frac{1}{2(\sigma^2)^2} - \frac{(X - \mu)^2}{(\sigma^2)^3}$$

Dist. não-informativas: Sentido Jeffreys

A informação de Fisher com respeito a σ^2 é

$$\begin{aligned} I(\sigma^2) &= -E_{X|\sigma^2} \left(\frac{1}{2(\sigma^2)^2} - \frac{(X - \mu)^2}{(\sigma^2)^3} \right) = \\ &= -\frac{1}{2(\sigma^2)^2} + \frac{E_{X|\sigma^2}(X - \mu)^2}{(\sigma^2)^3} = \frac{1}{2(\sigma^2)^2} \end{aligned} \quad (8)$$

Por definição, a distribuição *a priori* de Jeffreys para σ^2 é

$$\pi(\sigma^2) \propto \left[\frac{1}{2(\sigma^2)^2} \right]^{1/2} \propto \frac{1}{\sigma^2}$$

Análise de referência nos Dados Genéticos

- * Dados: 34 indivíduos com Síndrome de Down (6, 22 e 6, respectivamente, com 1, 2 e 3 alelos distintos no loco de interesse).
- * frequências alélicas: 0.12, 0.45, 0.09, 0.31, 0.01 e 0.02.

Para $\phi \in (0, 1)$, a verossimilhança

$$P(\mathbf{Y} = \mathbf{y} \mid \phi) = \frac{n!}{y_1! y_2! y_3!} [\theta_1(\phi)]^{y_1} [\theta_2(\phi)]^{y_2} [\theta_3(\phi)]^{y_3}, \quad (9)$$

- * Como o espaço paramétrico para ϕ é o intervalo $(0, 1)$, a distribuição *a priori* para ϕ , não-informativa no sentido de Bayes-Laplace é

$$\phi \sim \text{Uniforme}(0, 1)$$

Análise de referência nos Dados Genéticos

A informação de Fisher para ϕ associada ao modelo em (9) é

$$I(\phi) = n \left(\frac{a^2}{\theta_1(\phi)} + \frac{b^2}{\theta_2(\phi)} + \frac{c^2}{\theta_3(\phi)} \right),$$



onde $a = \sum_{i=1}^m p_i^3 - \sum_{i=1}^m p_i^2$ e, $b = \sum_{i,j=1}^m p_i^2 p_j - \sum_{i,j=1}^m p_i p_j$ e $c = \sum_{i,j,k=1}^m p_i p_j p_k$, para $i \neq j \neq k$. Consequentemente, a distribuição de Jeffreys para ϕ é

$$\pi(\phi) \propto \left(\frac{a^2}{\theta_1(\phi)} + \frac{b^2}{\theta_2(\phi)} + \frac{c}{\phi} \right)^{1/2}. \quad (10)$$

Esta distribuição é própria.

Análise de referência nos Dados Genéticos

Distribuições *a priori* de referência e *a posteriori* para ϕ .



mi Apesar das distribuições *a priori* serem diferentes, as informações que trazem sobre ϕ é fraca, gerando distribuições *a posteriori* muito similares.

Análise de referência nos Dados Genéticos

Table: Estimativas *a posteriori* para ϕ

Dist. <i>a prior</i>	Resumos <i>a posteriori</i>		
	Media	variância	Moda
Jeffreys	0.6417	0.0322	0.6374
Uniforme	0.6549	0.0305	0.6552

- * Estimador de máxima verossimilhança e variância assintótica são 0.6552 e 0.0481, respectivamente.