

# 7 - Elementos básicos de inferência Bayesiana.

**Prof. Vinícius D. Mayrink**

EST171 - Estatística Espacial

Sala: 4073

Email: [vdm@est.ufmg.br](mailto:vdm@est.ufmg.br)

1º semestre de 2024

Alguns conceitos básicos da abordagem Bayesiana para a inferência estatística são tratados aqui. O foco é descrever os elementos necessários para a construção de um modelo Bayesiano e as técnicas utilizadas para extrair informação relevante dos dados.

Assuma que  $X = (X_1, \dots, X_n)$  representa uma amostra aleatória contendo observações (dados) relacionadas ao estudo em desenvolvimento.

A função conjunta  $p(X|\theta)$  descreve o quão provável é esta amostra para diferentes valores do parâmetro de interesse  $\theta$ . Esta função é muitas vezes denotada por  $L(\theta; X)$  e conhecida como função de verossimilhança.

Desejamos estimar  $\theta$ . Em uma análise Bayesiana, o pesquisador caracteriza probabilisticamente (subjetivamente) sua incerteza a respeito de  $\theta$  antes que os dados sejam observados; somente o conhecimento prévio a respeito do problema em questão é levado em conta. Nesta etapa inicial, uma função de probabilidade ou função densidade  $p(\theta)$  será escolhida para descrever esta incerteza inicial; a distribuição de probabilidade associada a  $p(\theta)$  é denominada distribuição *a priori*.

Muita discussão surgiu a respeito da introdução de informação, diferente daquela trazida pelos dados, no procedimento de inferência. Hoje em dia, a aceitação desta abordagem é muito ampla no meio científico.

Entre os Bayesianos, a grande discussão envolve a especificação de distribuições *a priori* não informativas. Elas são usadas quando nenhum conhecimento prévio está disponível sobre o parâmetro de interesse, determinando que apenas a informação dos dados deve interferir na análise.

Exemplo: Uma moeda (ela pode ser viciada) é lançada 6 vezes. Desejamos avaliar a probabilidade de obtermos “cara” no 7º lançamento. Considere  $H$  = Histórico ou informação disponível. Notação:  $X_i = 1$  se o  $i$ -ésimo lançamento resulta em “cara” (0 caso contrário).

Primeiro pensamento:  $p(X_7 = 1|H_0) = 0.5$ .

Informação adicional:

$H_1 = \{X_1 = 1, X_2 = 1, X_3 = 1, X_4 = 1, X_5 = 1, X_6 = 0\}$ .

Desejamos obter:  $p(X_7 = 1|H_1)$ .

Suposição: A ordem de 1's e 0's nos dados não é relevante.  
A informação amostral importante é: “1 coroa e 5 caras”.

Modelo:  $p(X_i|\theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$ .

Função de verossimilhança:

$$p(X_1 = 1, X_2 = 1, X_3 = 1, X_4 = 1, X_5 = 1, X_6 = 0|\theta) = \theta^5(1 - \theta)^1.$$

Estimativa de máxima verossimilhança:  $\hat{\theta} = 5/6 = 0.83$ .

$$\begin{aligned} p(X_7 = 1|H_1) &= \int_0^1 P(X_7 = 1, \theta|H_1) d\theta \\ &= \int_0^1 p(X_7 = 1|\theta, H_1) p(\theta|H_1) d\theta \\ &\quad \text{por independência teremos...} \\ &= \int_0^1 p(X_7 = 1|\theta) p(\theta|H_1) d\theta \\ &= \int_0^1 \theta p(\theta|H_1) d\theta = E(\theta|H_1) \end{aligned}$$

Distribuição *a priori*:  $0 \leq \theta \leq 1$ , portanto, assumamos a distribuição Beta.

$$p(\theta) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1}(1-\theta)^{b-1} \text{ para } 0 \leq \theta \leq 1 \text{ e } a, b > 0.$$

Especificação *a priori* vaga:  $a = b = 1 \Rightarrow \theta \sim U(0, 1)$ .

$$\begin{aligned} p(\theta|H_1) &= \frac{p(H_1, \theta)}{p(H_1)} = \frac{p(H_1|\theta)p(\theta)}{p(H_1)} \\ &\propto \theta^5(1-\theta) \theta^{a-1}(1-\theta)^{b-1} \\ &\propto \theta^{5+a-1}(1-\theta)^{1+b-1} \end{aligned}$$

este é o núcleo de uma  $\text{Beta}(5+a, 1+b)$ .

Note que  $p(H_1)$  não depende de  $\theta$  (constante de proporcionalidade).

$$\begin{aligned} p(X_7 = 1|H_1) &= E(\theta|H_1) = \frac{(a+5)}{(a+b+6)} = \\ &= 6/8 = 0.75 \text{ se } a = b = 1, \\ &= 7/10 = 0.70 \text{ se } a = b = 2. \end{aligned}$$

## Teorema de Bayes

Distribuição *a priori*:  $p(\theta|H)$ .

Função de verossimilhança:  $p(X|\theta, H)$ .

Distribuição *a posteriori*:  $p(\theta|X, H) = \frac{p(\theta, X|H)}{p(X|H)} = \frac{p(X|\theta, H) p(\theta|H)}{p(X|H)}$

sendo  $p(X|H) = \int_{\Theta} p(X, \theta|H) d\theta$ .

Alternativamente, escrevemos  $p(\theta|X) \propto p(X|\theta) p(\theta)$ .

Veja que  $p(\theta|X) = k p(X|\theta) p(\theta)$  com:  $1 = \int_{\Theta} p(\theta|X) d\theta = k \int_{\Theta} p(X|\theta) p(\theta) d\theta$ .

Portanto:  $k^{-1} = p(X|H) = \int_{\Theta} p(X|\theta) p(\theta) d\theta = E_{\theta}[p(X|\theta)]$ .

Esta é a distribuição preditiva (ou marginal) de  $X$ .

Especificação a priori. Seja  $\theta$  uma quantidade desconhecida.

Se  $\theta$  é discreto, uma probabilidade *a priori* para cada possível valor de  $\theta$  poderá ser avaliada diretamente via p.m.f..

Para um espaço paramétrico contínuo, o conhecimento *a priori* sobre  $\theta$  pode ser usado para especificar uma p.d.f. *a priori* com certa forma funcional. Exemplo:

- $\theta$  apresenta distribuição simétrica em relação à moda;
- sua p.d.f. decai rapidamente ao se distanciar da moda;
- regiões longe da moda apresentam probabilidades irrelevantes.

Estas suposições caracterizam uma Normal com hiperparâmetros especificados de acordo com  $H$ .

Se uma probabilidade nula é atribuída a um subconjunto dos possíveis  $\theta$ , nenhuma informação observada irá mudar a especificação (o que é inadequado).

**Regra de Cromwell (Lindley):** Devemos sempre associar uma probabilidade *a priori* não nula para cada possível valor de  $\theta$ , mesmo que alguns deles sejam julgados como muito improváveis.

É possível mostrar que se  $(X|\theta) \sim N(\theta, \sigma^2)$  e  $\theta \sim N(m, v)$ , então  $(\theta|X) \sim N(m^*, v^*)$ . Portanto, em um modelo Normal, se iniciarmos com uma distribuição *a priori* Normal, teremos uma distribuição *a posteriori* Normal.

Cada nova observação Normal obtida determina mudanças nos parâmetros da distribuição *a posteriori* (que continua sendo Normal).

**Definição:** Seja  $\mathcal{F} = \{p(X|\theta); \theta \in \Theta\}$  uma família de distribuições relacionadas à amostra  $X$ . A classe  $\mathcal{C}$  de distribuições é dita ser uma família conjugada com respeito a  $\mathcal{F}$  se para todo  $p(X|\theta) \in \mathcal{F}$  e  $p(\theta) \in \mathcal{C}$  temos  $p(\theta|X) \in \mathcal{C}$ .

Podemos dizer que a classe de distribuições Normais é uma família conjugada com relação à classe de distribuições amostrais Normais.



## As principais famílias conjugadas

Distribuição Binomial: A família de distribuições Beta é conjugada com o modelo Bernoulli ou Binomial.

Distribuição  $N(\mu, \sigma^2)$  com variância conhecida: A família Normal é conjugada com o modelo Normal. Para uma amostra de tamanho  $n$  temos:

$$L(\mu; X) \propto \exp \left\{ -\frac{1}{2\sigma^2} \left[ -2\mu \sum_{i=1}^n X_i + n\mu^2 \right] \right\}.$$

Assumindo  $\mu \sim N(m, v)$  teremos  $(\mu|X) \sim N(m^*, v^*)$  sendo:

$$v^* = \left( \frac{n}{\sigma^2} + \frac{1}{v} \right)^{-1} \quad \text{e} \quad m^* = v^* \left( \frac{\sum_{i=1}^n X_i}{\sigma^2} + \frac{m}{v} \right).$$

## Distribuição Poisson:

Suponha que  $X = \{X_1, \dots, X_n\}$  é uma amostra aleatória da  $\text{Poisson}(\theta)$ .

A verossimilhança será:

$$p(X|\theta) = \prod_{i=1}^n p(X_i|\theta) = \prod_{i=1}^n \frac{\theta^{X_i} \exp\{-\theta\}}{X_i!} \propto \theta^{\sum_{i=1}^n X_i} \exp\{-n\theta\}$$

A família de distribuições Gama é conjugada com o modelo Poisson.

Assuma  $\theta \sim \text{Ga}(a, b)$ , então  $(\theta|X) \sim \text{Ga}(a^*, b^*)$ , sendo:

$$a^* = a + \sum_{i=1}^n X_i \quad \text{e} \quad b^* = b + n.$$

## Distribuição Exponencial:

Suponha que  $X = \{X_1, \dots, X_n\}$  é uma amostra aleatória da  $\text{Exp}(\theta)$ . A verossimilhança será:

$$p(X|\theta) = \prod_{i=1}^n p(X_i|\theta) = \prod_{i=1}^n \theta \exp\{-\theta X_i\} \propto \theta^n \exp\left\{-\theta \sum_{i=1}^n X_i\right\}.$$

A família de distribuições Gama é conjugada com o modelo Exponencial. Assuma  $\theta \sim \text{Ga}(a, b)$ , então  $(\theta|X) \sim \text{Ga}(a^*, b^*)$ , sendo:

$$a^* = a + n \quad \text{e} \quad b^* = b + \sum_{i=1}^n X_i.$$

## Distribuição Multinomial:

Suponha que  $X = \{X_1, \dots, X_q\}$  e  $\theta = (\theta_1, \dots, \theta_q)$  sejam, respectivamente, o número de casos observados e as probabilidades associadas a cada uma de  $q$  categorias; assuma tamanho amostral  $n$ . Considere  $\sum_{i=1}^q X_i = n$  e  $\sum_{i=1}^q \theta_i = 1$ . Dizemos que  $X$  tem distribuição multinomial com parâmetros  $n$  e  $(\theta_1, \dots, \theta_q)$ .

$$L(\theta; X) = p(X|\theta) = \frac{n!}{\prod_{i=1}^q X_i!} \prod_{i=1}^q \theta_i^{X_i} \propto \prod_{i=1}^q \theta_i^{X_i}.$$

Este núcleo é o mesmo da distribuição Dirichlet.

Se  $\theta$  segue a distribuição Dirichlet com parâmetro  $a = (a_1, \dots, a_q)'$ , sendo  $a_i > 0$  e  $\sum_{i=1}^q a_i = \alpha$ , então sua p.d.f. será:

$$p(\theta) = \frac{\Gamma(\alpha)}{\prod_{i=1}^q \Gamma(a_i)} \prod_{i=1}^q \theta_i^{a_i-1}.$$

A família Dirichlet com parâmetros  $a = (a_1, \dots, a_q)$ , notação  $\text{Dir}(a)$ , é conjugada com o modelo multinomial.

A distribuição *a posteriori* será então:

$$p(\theta|X) \propto \left[ \prod_{i=1}^q \theta_i^{X_i} \right] \left[ \prod_{i=1}^q \theta_i^{a_i-1} \right] = \prod_{i=1}^q \theta_i^{X_i+a_i-1}$$

a qual é uma Dirichlet com parâmetro  $a^* = (a_1 + X_1, \dots, a_q + X_q)$  e denotada por  $(\theta|X) \sim \text{Dir}(a^*)$ .

A constante de proporcionalidade é dada por:  $\frac{\Gamma(\alpha+n)}{\prod_{i=1}^q \Gamma(a_i+X_i)}$ .

Esta análise conjugada generaliza a análise para amostras da Bernoulli com distribuição *a priori* Beta para a probabilidade de sucesso.

## Distribuição $N(\mu, \sigma^2)$ com média conhecida e variância desconhecida:

Seja  $X = (X_1, \dots, X_p)$  uma amostra aleatória da  $N(\mu, \sigma^2)$ , sendo  $\mu$  conhecido e  $\phi = 1/\sigma^2$  a precisão desconhecida.

A maneira de parametrizar uma distribuição é escolhida de acordo com o interesse do pesquisador. Uma escolha de parametrização pode facilitar os cálculos, a interpretação e a implementação computacional de um problema.

Função de verossimilhança:

$$L(\phi; X) = p(X|\mu, \phi) \propto \phi^{n/2} \exp \left\{ -\frac{\phi}{2} \left[ \sum_{i=1}^n X_i^2 - 2\mu \sum_{i=1}^n X_i + n\mu^2 \right] \right\}.$$

A distribuição *a priori* conjugada deve ter um núcleo parecido com a expressão de  $L(\phi; X)$ . Podemos considerar  $\phi \sim Ga(a, b)$ , então

$$\begin{aligned} p(\phi|X) &\propto L(\phi; X) p(\phi) \\ &\propto \phi^{n/2+a-1} \exp \left\{ -\phi \left[ b + \frac{1}{2} \left( \sum_{i=1}^n X_i^2 - 2\mu \sum_{i=1}^n X_i + n\mu^2 \right) \right] \right\}. \end{aligned}$$

A última expressão é o núcleo da  $Ga(a^*, b^*)$  sendo  $a^* = a + n/2$  e  $b^* = b + \frac{1}{2} (\sum_{i=1}^n X_i^2 - 2\mu \sum_{i=1}^n X_i + n\mu^2)$ .

## Distribuição $N(\mu, \sigma^2)$ com média e variância desconhecidas:

Assuma que  $X_1, \dots, X_n$  é amostra aleatória da  $N(\mu, \sigma^2)$ , sendo  $\phi = 1/\sigma^2$  a precisão. Neste caso, precisamos especificar uma distribuição *a priori* conjunta para  $(\mu, \phi)$ . Isso será feito em dois estágios:

- $(\mu|\phi) \sim N[m, v/\phi]$ ;
- $\phi \sim Ga(a, b)$ ;

sendo  $(m \in \mathbb{R}, v > 0, a > 0, b > 0)$  especificados de acordo com a informação inicial  $H$ .

Função de verossimilhança:

$$L(\mu, \phi; X) \propto \phi^{n/2} \exp \left\{ -\frac{\phi}{2} \left[ \sum_{i=1}^n X_i^2 - 2\mu \sum_{i=1}^n X_i + n\mu^2 \right] \right\}.$$



## Distribuição *a posteriori*:

$$\begin{aligned} p(\mu, \phi | X) &\propto p(X | \mu, \phi) p(\mu, \phi) \\ &\propto p(X | \mu, \phi) p(\mu | \phi) p(\phi) \\ &\propto \phi^{n/2} \exp \left\{ -\frac{\phi}{2} \left[ \sum_{i=1}^n X_i^2 - 2\mu \sum_{i=1}^n X_i + n\mu^2 \right] \right\} \times \\ &\quad \times v^{-1/2} \phi^{1/2} \exp \left\{ -\frac{\phi}{2v} [\mu^2 - 2\mu m + m^2] \right\} \times \\ &\quad \times \phi^{a-1} \exp \{-b\phi\} \\ &\text{após alguns cálculos...} \\ &\propto \phi^{A-1} \exp \{-\phi B\} W^{-1/2} \exp \left\{ -\frac{1}{2W} (\mu - M)^2 \right\} \end{aligned}$$

Na última expressão temos os núcleos:

$(\mu|\phi, X) \sim N(M, W)$  e  $(\phi|X) \sim Ga(A, B)$  sendo:

$$M = \left(n + \frac{1}{v}\right)^{-1} \left[\frac{m}{v} + \sum_{i=1}^n X_i\right], \quad W = \frac{v}{(nv+1)\phi},$$
$$B = b + \frac{m^2}{2v} + \frac{\sum_{i=1}^n X_i^2}{2} - \frac{1}{2} \left(n + \frac{1}{v}\right) M^2 \quad \text{e} \quad A = a + \frac{n}{2}.$$


Conclusão:  $(\mu|\phi, X) \sim N(M, W)$  e  $(\phi|X) \sim Ga(A, B)$ .

Neste caso, a distribuição *a priori* e *a posteriori* são denominadas “Normal-Gama”.

A família de distribuições Normal-Gama é conjugada ao modelo Normal com média e a variância desconhecidas.

## Estimação

Considere a p.d.f. *a posteriori* abaixo ilustrando algumas dificuldades que podemos enfrentar no procedimento de inferência Bayesiana. Apesar das dificuldades, temos aqui tudo que precisamos para uma descrição probabilística sobre  $\theta$ .



O gráfico da p.d.f. *a posteriori* é a melhor descrição que temos no processo de inferência Bayesiana. Entretanto, algumas vezes é útil sumarizar ainda mais a informação *a posteriori*.

**Estimação pontual:** A forma mais simples de sumarização é a estimação pontual, onde buscamos determinar um único valor representando a quantidade desconhecida  $\theta$ . Denote por  $\hat{\theta}$  o estimador pontual de  $\theta$ ; devemos considerar estimadores que representam uma medida de centralidade. Três escolhas familiares são:

- Média *a posteriori*:  $\hat{\theta} = E(\theta|X)$ ;
- Mediana *a posteriori*:  $\hat{\theta}$  é tal que  $\int_{-\infty}^{\hat{\theta}} p(\theta|X)d\theta = 0.5$ ;
- Moda *a posteriori*:  $\hat{\theta}$  é tal que  $p(\hat{\theta}|X) = \sup_{\theta} p(\theta|X)$ .

**Estimação intervalar:** Seja  $\theta$  uma quantidade desconhecida definida em  $\Theta$ . Uma região  $\mathcal{C} \subset \Theta$  é uma região de  $100(1-\alpha)\%$  de credibilidade para  $\theta$  se  $P(\theta \in \mathcal{C}|X) \geq 1 - \alpha$ . Neste caso,  $1 - \alpha$  é o “nível de credibilidade”. Se  $\theta$  é um escalar, a região  $\mathcal{C}$  poderá ser um intervalo do tipo  $[c_1, c_2]$ .

Exemplo: Seja  $X_1, \dots, X_n$  uma amostra aleatória tal que  $X_i \sim N(\mu, \sigma^2)$  com variância  $\sigma^2$  conhecida. Considere a distribuição *a priori*:  $\mu \sim N[m, v]$  sendo  $m$  e  $v$  especificados pelo pesquisador.

Função de verossimilhança:

$$\begin{aligned} p(X|\mu) &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{1}{2\sigma^2} [X_i^2 - 2X_i\mu + \mu^2] \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n X_i^2 - 2\mu \sum_{i=1}^n X_i + n\mu^2 \right] \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left[ \frac{n}{\sigma^2} \mu^2 - 2\mu \frac{\sum_{i=1}^n X_i}{\sigma^2} \right] \right\} \end{aligned}$$

A distribuição *a posteriori* será dada por  $p(\mu|X) \propto p(X|\mu) p(\mu)$ :


$$\begin{aligned} p(\mu|X) &\propto \exp\left\{-\frac{1}{2}\left[\frac{n}{\sigma^2}\mu^2 - 2\mu\frac{\sum_{i=1}^n X_i}{\sigma^2}\right]\right\} \exp\left\{-\frac{1}{2}\left[\frac{1}{v}\mu^2 - 2\mu\frac{m}{v}\right]\right\}. \\ &\propto \exp\left\{-\frac{1}{2}\left(\frac{n}{\sigma^2} + \frac{1}{v}\right)\left[\mu^2 - 2\mu\left(\frac{n}{\sigma^2} + \frac{1}{v}\right)^{-1}\left(\frac{\sum_{i=1}^n X_i}{\sigma^2} + \frac{m}{v}\right)\right]\right\} \end{aligned}$$

A última expressão é o núcleo da  $N(m^*, v^*)$  com

$$v^* = \left(\frac{n}{\sigma^2} + \frac{1}{v}\right)^{-1} \quad \text{e} \quad m^* = v^* \left(\frac{\sum_{i=1}^n X_i}{\sigma^2} + \frac{m}{v}\right).$$

Dado  $X$ , podemos escrever:  $\frac{\mu - m^*}{\sqrt{v^*}} \sim N(0, 1)$ .

Muitos intervalos com  $100(1-\alpha)\%$  de credibilidade podem ser construídos para  $\mu$ .



O primeiro gráfico mostra um intervalo Bayesiano de credibilidade  $100(1-\alpha)\%$  HPD (*Highest Posterior Density*) para o caso Normal. O segundo gráfico também mostra um intervalo de credibilidade  $100(1-\alpha)\%$ , mas ele não é HPD. O intervalo HPD terá amplitude menor.

## Computação Bayesiana - Gibbs Sampling

O Teorema de Bayes fornece  $p(\theta|X) = \frac{p(X|\theta) p(\theta)}{p(X)}$  sendo  $p(X)$  uma constante normalizadora que precisa ser determinada para que a expressão fechada da distribuição *a posteriori* seja conhecida.

Em muitos casos, a constante normalizadora não pode ser obtida (cálculos complicados). Conheceremos apenas o núcleo da distribuição alvo:

$p(\theta|X) \propto p(X|\theta) p(\theta)$ . Para superar este obstáculo, utilizaremos métodos computacionais que permitem amostrar indiretamente valores da distribuição *a posteriori*.

O *Gibbs Sampling* foi a primeira classe de esquemas largamente empregada para simulação estocástica via cadeia de *Markov*.

Origem: Discutido pela primeira vez em Geman e Geman (1984). Entretanto, Gelfand e Smith (1990) mostraram que o Gibbs poderia ser usado, em muitos casos, para amostrar da distribuição *a posteriori*.



Desejamos amostrar da distribuição de interesse  $p(\theta|X)$ , sendo  $\theta = (\theta_1, \theta_2, \dots, \theta_d)'$ . A amostragem direta não é possível.

O Gibbs Sampling é baseado em gerações sucessivas a partir de distribuições condicionais completas  $p(\theta_i|\theta_{-i})$  sendo  $\theta_{-i} = (\theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_d)'$ .

O algoritmo:

- 1 Inicializar o contador de iterações ( $j = 1$ ) e escolher os valores iniciais  $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_d^{(0)})'$ ;
- 2 Obter o novo valor  $\theta^{(j)} = (\theta_1^{(j)}, \dots, \theta_d^{(j)})'$  a partir de gerações sucessivas considerando as distribuições condicionais completas:

$$\begin{aligned}\theta_1^{(j)} &\sim p(\theta_1 | \theta_2^{(j-1)}, \dots, \theta_d^{(j-1)}), \\ \theta_2^{(j)} &\sim p(\theta_2 | \theta_1^{(j)}, \theta_3^{(j-1)}, \dots, \theta_d^{(j-1)}), \\ &\vdots \\ \theta_d^{(j)} &\sim p(\theta_d | \theta_1^{(j)}, \dots, \theta_{d-1}^{(j)}); \end{aligned}$$

- 3 Faça  $j = j + 1$  e retorne ao passo 2 até obter a amostra desejada.

Conforme  $j$  cresce a cadeia aproxima-se de uma condição de equilíbrio. Após algumas iterações (período de aquecimento - *burn in*) ela irá convergir e neste momento o valor  $\theta^{(j)}$  será tratado como uma observação da distribuição  $p(\theta|X)$ .

A amostra gerada não é exatamente aleatória; haverá dependência entre os valores da cadeia. Mesmo que  $n$  seja grande, se a autocorrelação da cadeia é alta, o tamanho efetivo da amostra será menor que  $n$ . Estratégia para inferência: formar a amostra final com valores selecionados a cada  $L$  iterações ( $L = \text{lag}$ ).

O *Gibbs Sampling* não é o único método da classe *Markov Chain Monte Carlo* (MCMC). Outro método MCMC popular é o *Metropolis-Hastings*.

Se alguma condicional completa é desconhecida, podemos utilizar outros métodos (*Metropolis-Hastings*, *Slice Sampling*, *ARS - Adaptive Rejection Sampling*, etc). como um passo dentro do *Gibbs Sampling*. Esta estratégia é usada pelo *OpenBugs* (*BUGS = Bayesian inference Using Gibbs Sampling*).

**Autocorrelação:** Seja  $z_1, \dots, z_n$  uma série de observações. A autocorrelação estimada de ordem  $j$  é dada por:  $\hat{\rho}_j = \left[ \sum_{i=j+1}^n (z_i - \bar{z})(z_{i-j} - \bar{z}) \right] / \sum_{i=1}^n (z_i - \bar{z})^2$ .